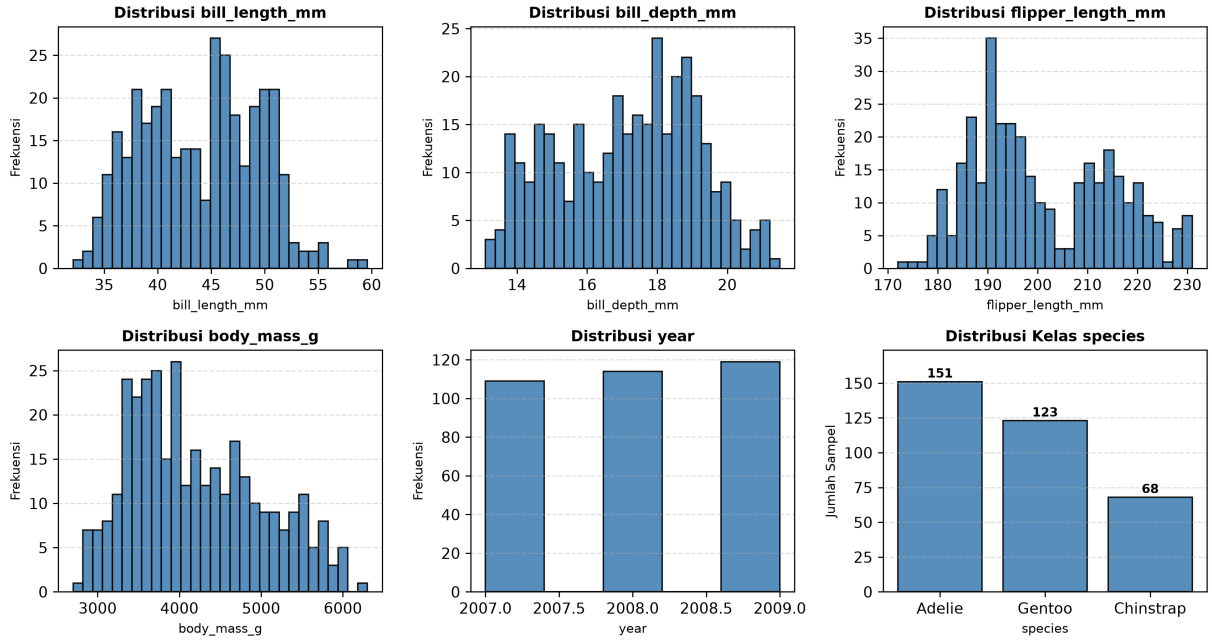
Tugas Praktikum: Clustering Advanced pada Dataset Palmer Penguins

Nama : Fahmi Alfayadh
NRP : 5054251015
Kelas : Data Mining (N)

Distribusi Data

Gambar 1: Distribusi histogram lima fitur numerik dan frekuensi kelas species

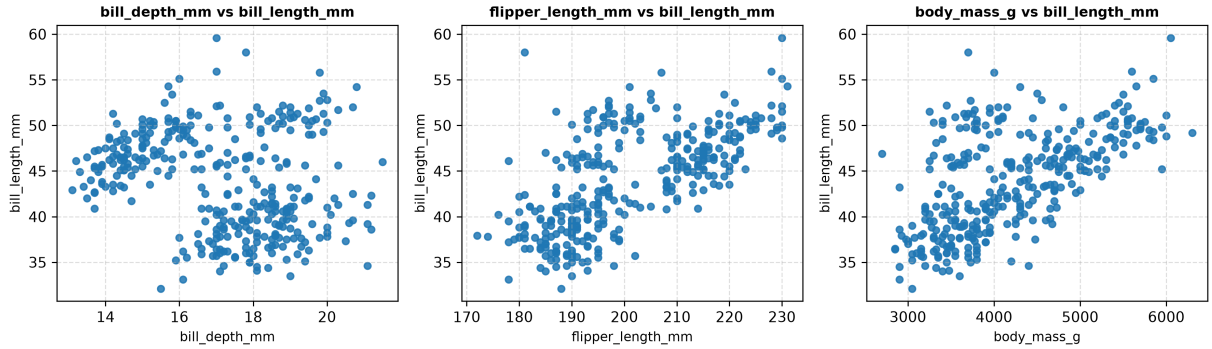


Dataset terdiri atas 344 baris dan 8 kolom (species, island, bill_length_mm, bill_depth_mm, flipper_length_mm, body_mass_g, sex, dan year). Pada data mentah, empat fitur morfologi numerik terbaca sebagai tipe string karena memuat nilai literal "NA". Setelah konversi tipe data menjadi Float32, ditemukan masing-masing 2 missing values pada bill_length_mm, bill_depth_mm, flipper_length_mm, dan body_mass_g, serta 0 baris duplikat. Penghapusan baris bernilai null menghasilkan 342 baris data valid yang terbagi menjadi 3 kelas species: Adelie (151), Gentoo (123), dan Chinstrap (68).

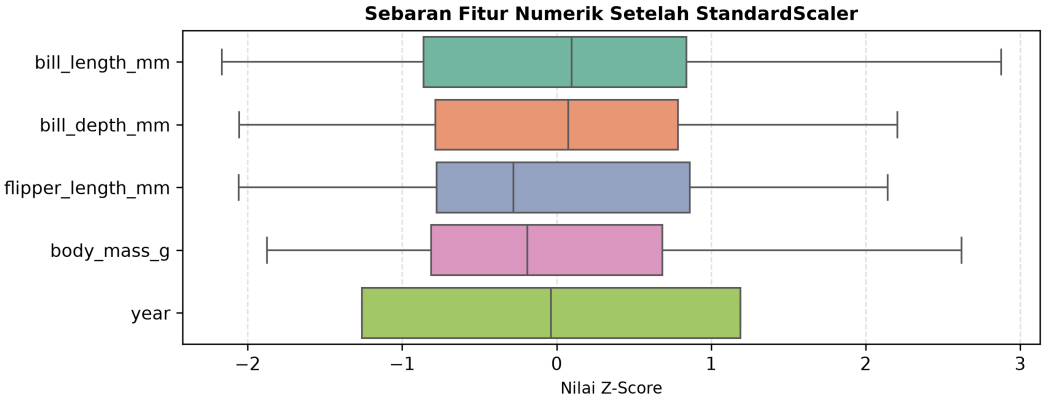
Tabel 1: Ringkasan statistik lima fitur numerik setelah praproses (n = 342)

Fitur Numerik	Mean	Std. Dev.	Min	Median (50%)	Max
bill_length_mm	43,92	5,46	32,10	44,50	59,60
bill_depth_mm	17,15	1,97	13,10	17,30	21,50
flipper_length_mm	200,92	14,06	172,00	197,00	231,00
body_mass_g	4.201,75	801,95	2.700,00	4.050,00	6.300,00
year	2.008,03	0,82	2.007,00	2.008,00	2.009,00

Gambar 2: Sebaran scatter plot antar fitur morfologi terhadap bill_length_mm



Gambar 3: Sebaran nilai fitur numerik setelah transformasi StandardScaler



Seluruh lima fitur numerik (X berukuran 342 x 5) distandardisasi menggunakan StandardScaler sebelum pemodelan agar perbedaan skala satuan (seperti body_mass_g dalam ribuan gram dan bill_depth_mm dalam puluhan milimeter) tidak mendominasi perhitungan jarak.

Pendekatan yang Digunakan

Empat algoritma clustering diterapkan pada data terstandardisasi (X_transformed) untuk membandingkan pembentukan klaster berdasarkan pendekatan hirarki, kepadatan, graf spektral, dan model campuran probabilistik:

1. Agglomerative Clustering

Pendekatan bottom-up hierarchical clustering dengan jumlah klaster n_clusters = 3 dan kriteria penggabungan linkage = "ward" yang meminimalkan varians intra-klaster.

2. DBSCAN (Density-Based Spatial Clustering of Applications with Noise)

Pengelompokan berbasis kepadatan dengan metrik jarak euclidean dan min_samples = 5. Dilakukan pengujian parameter eps pada rentang [0,1; 0,5; 1,0; 2,0; 5,0] dan dipilih eps = 1,0 untuk evaluasi komparatif.

3. Spectral Clustering

Pengelompokan berbasis eigenvektor matriks afinitas graf dengan n_clusters = 3, affinity = "nearest_neighbors", dan assign_labels = "kmeans".

4. Gaussian Mixture Model (GMM)
Model probabilistik berbasis algoritma Expectation-Maximization dengan n_components = 3 dan covariance_type = "full".

Tabel 2: Konfigurasi parameter keempat algoritma clustering

Algoritma	Pendekatan	Parameter Utama
Agglomerative Clustering	Hirarki (Bottom-Up)	n_clusters = 3, linkage = "ward"
DBSCAN	Berbasis Kepadatan	eps = 1,0 (uji: 0,1–5,0), min_samples = 5, metric = "euclidean"
Spectral Clustering	Graf Spektral	n_clusters = 3, affinity = "nearest_neighbors", assign_labels = "kmeans"
Gaussian Mixture Model	Probabilistik (EM)	n_components = 3, covariance_type = "full"

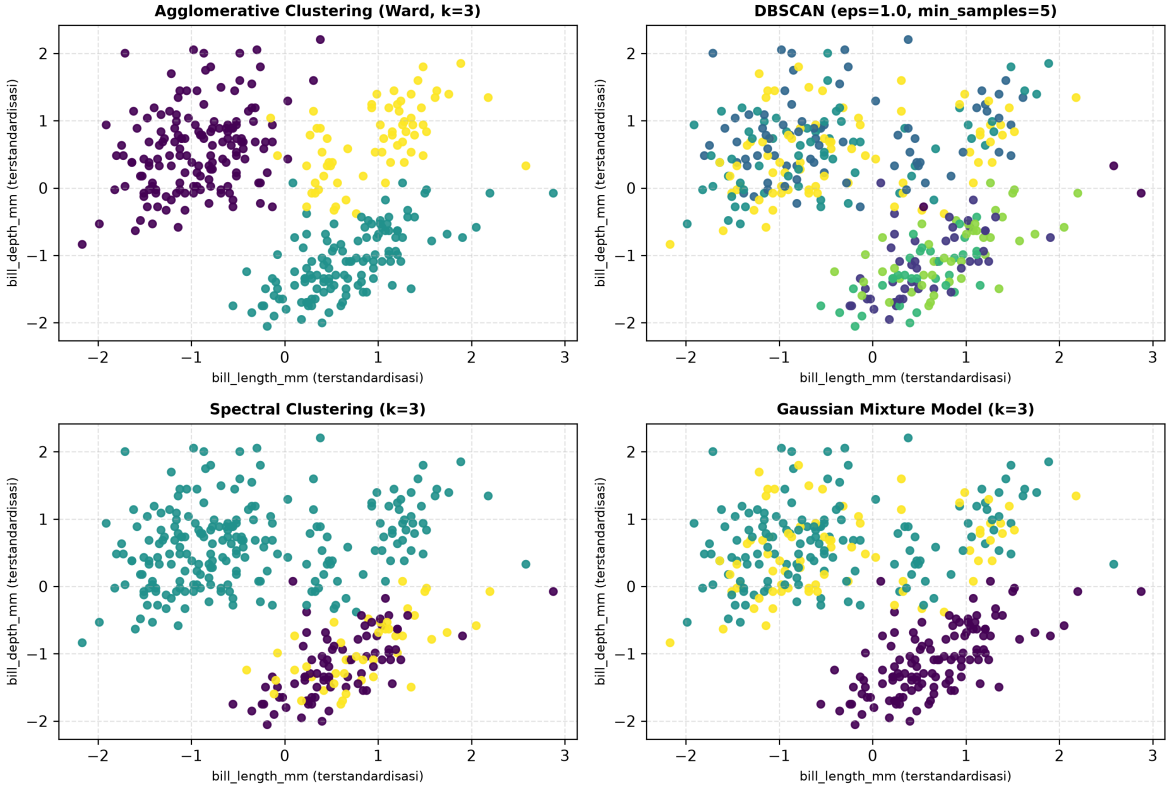
Hasil Evaluasi Model

Evaluasi kinerja dilakukan menggunakan tiga metrik internal tanpa label (Silhouette Score, Calinski-Harabasz Score, dan Davies-Bouldin Score) serta satu metrik eksternal terhadap label asli species (Normalized Mutual Information / NMI).

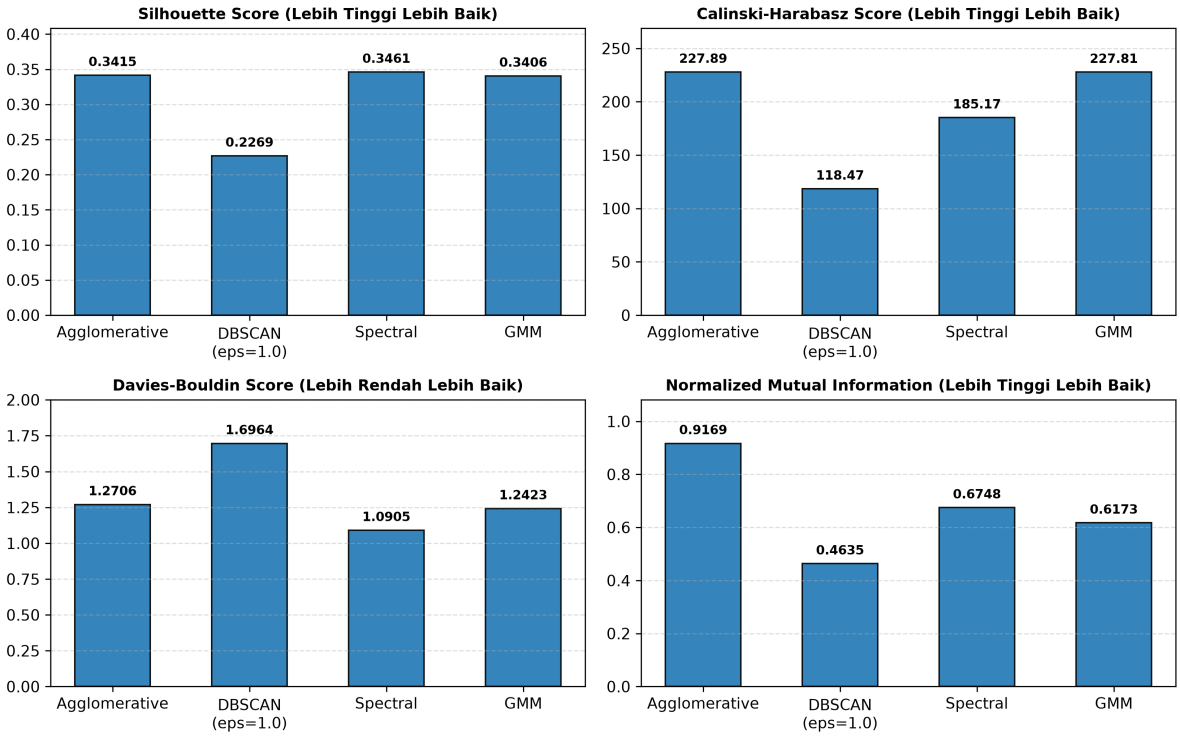
Tabel 3: Perbandingan skor evaluasi internal dan eksternal keempat model

Model Clustering	Silhouette Score	Calinski-Harabasz	Davies-Bouldin	NMI Score
Agglomerative Clustering	0,3415	227,89	1,2706	0,9169
DBSCAN (eps = 1,0)	0,2269	118,47	1,6964	0,4635
Spectral Clustering	0,3461	185,17	1,0905	0,6748
Gaussian Mixture Model	0,3406	227,81	1,2423	0,6173

Gambar 4: Visualisasi pemetaan klaster keempat model pada fitur bill_length_mm dan bill_depth_mm terstandardisasi



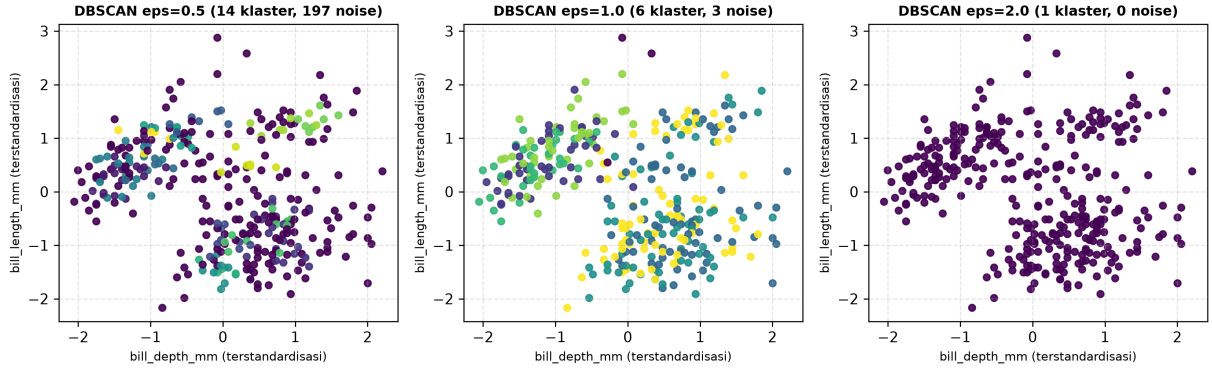
Gambar 5: Perbandingan empat metrik evaluasi pada seluruh model clustering



Tabel 4: Sensitivitas parameter eps pada DBSCAN (min_samples = 5)

Nilai eps	Jumlah Klaster Terbentuk	Jumlah Titik Noise	Keterangan Sebaran
0,1	0	342 (100,0%)	Seluruh sampel diklasifikasikan sebagai noise
0,5	14	197 (57,6%)	Terfragmentasi menjadi banyak klaster kecil
1,0	6	3 (0,9%)	Sebagian besar titik terkelompok, namun melebihi 3 kelas
2,0	1	0 (0,0%)	Seluruh sampel menyatu ke dalam satu klaster
5,0	1	0 (0,0%)	Seluruh sampel menyatu ke dalam satu klaster

Gambar 6: Perubahan pembentukan klaster DBSCAN pada variasi eps = 0,5, eps = 1,0, dan eps = 2,0



Perbandingan hasil eksperimen keempat algoritma:

1. Agglomerative Clustering

Mencapai NMI tertinggi (**0,9169**) dengan Calinski-Harabasz Score sebesar **227,89** dan Silhouette Score **0,3415**. Pemisahan tiga klaster terlihat selaras dengan sebaran tiga spesies pada bidang morfologi.

2. Spectral Clustering

Mencatat Silhouette Score tertinggi **(0,3461)** dan Davies-Bouldin terendah (1,0905), namun NMI lebih rendah **(0,6748)**. Pada konstruksi graf nearest_neighbors muncul peringatan bahwa graf tidak terhubung penuh (not fully connected), dan visualisasi menunjukkan penggabungan sebagian kelompok.

3. Gaussian Mixture Model

Mencapai Calinski-Harabasz tertinggi kedua (227,81) dan Silhouette 0,3406, namun pada inisialisasi random_state = 42 menghasilkan NMI 0,6173 karena sensitivitas algoritma EM terhadap konvergensi lokal dan keberadaan fitur diskrit year.

4. DBSCAN: Pada eps = 1,0 mencatat skor terendah di seluruh metrik (Silhouette 0,2269; Calinski-Harabasz 118,47; Davies-Bouldin 1,6964; NMI 0,4635) dan membentuk 6 klaster dengan 3 titik noise, sehingga tidak mampu merekonstruksi pemisahan tiga spesies secara stabil pada rentang eps yang diuji.

Kesimpulan

Berdasarkan hasil pengujian empat algoritma clustering pada 342 data valid Palmer Penguins dengan 5 fitur numerik terstandardisasi:

1. Kinerja Model Terbaik (Agglomerative Clustering):

Agglomerative Clustering (linkage = "ward", n_clusters = 3) menunjukkan keseimbangan performa paling konsisten antara validitas internal dan kesesuaian terhadap label spesies, dengan NMI tertinggi (0,9169), Calinski-Harabasz Score 227,89, dan Silhouette Score 0,3415.

2. Keterbatasan DBSCAN dan Sensitivitas Parameter:

DBSCAN sangat sensitif terhadap pemilihan radius eps pada ruang fitur 5 dimensi: nilai eps <= 0,5 menghasilkan proporsi noise tinggi (57,6%–100%), nilai eps = 1,0 memecah data menjadi 6 klaster (NMI 0,4635), sedangkan eps >= 2,0 menggabungkan seluruh data menjadi 1 klaster.

Kesimpulan Akhir (Takeaway)

Untuk dataset berdimensi rendah dengan struktur kelompok yang relatif terpisah seperti Palmer Penguins, pendekatan hirarki Agglomerative Clustering (Ward) memberikan partisi yang paling sesuai dengan pengelompokan spesies dibandingkan DBSCAN, Spectral Clustering, maupun GMM.

Penyertaan fitur bertipe diskrit seperti year (2007–2009) ke dalam ruang fitur numerik memengaruhi jarak antar sampel dan konvergensi model probabilistik seperti GMM serta graf konektivitas pada Spectral Clustering.