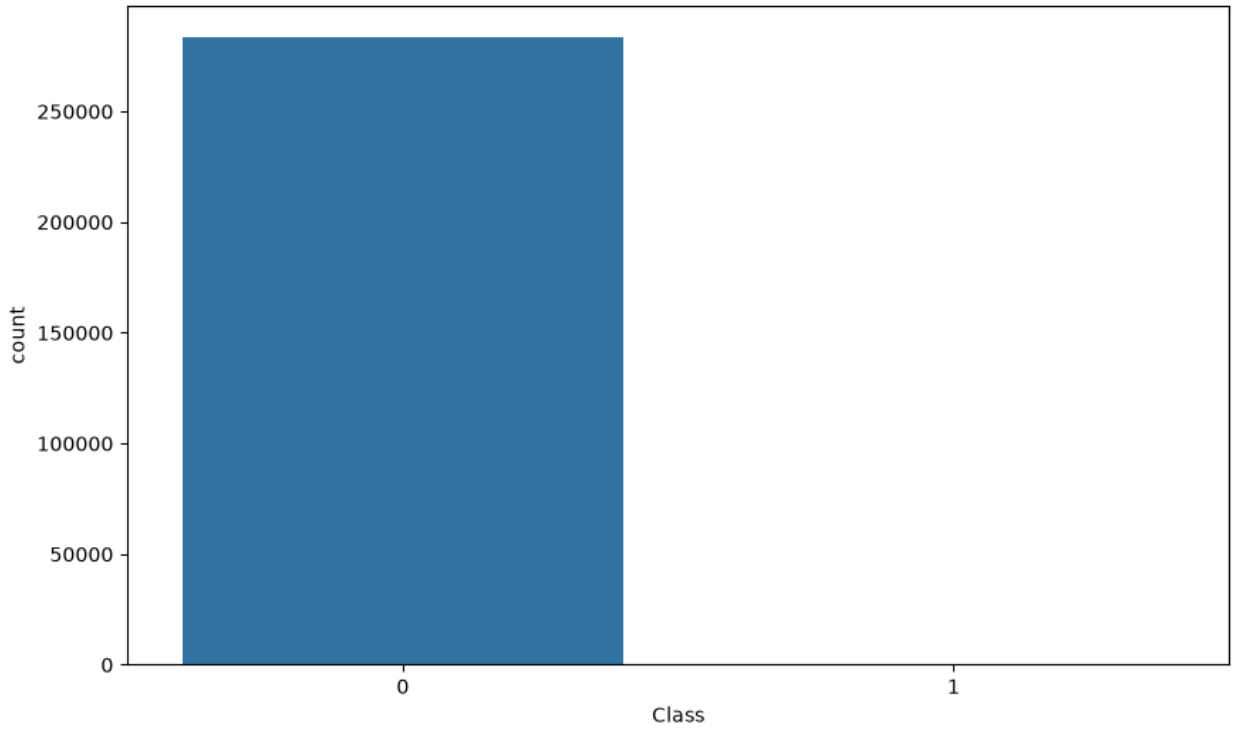
Tugas Praktikum 3: Classification dengan Ensemble Method & Class Imbalance

Nama : Fahmi Alfayadh
NRP : 5054251015

Distribusi Data



Gambar 1: Distribusi data class 1 dan 0

Dataset memiliki distribusi yang sangat timpang. Class 0 memiliki **283253** data dan class 1 hanya memiliki **473** data dengan perbandingan class 0 dan 1 adalah 1 :598. Bagi kebanyakan kasus, distribusi seperti ini merupakan kondisi yang perlu diperhatikan dan diperlukan strategi khusus untuk tahap modelling.

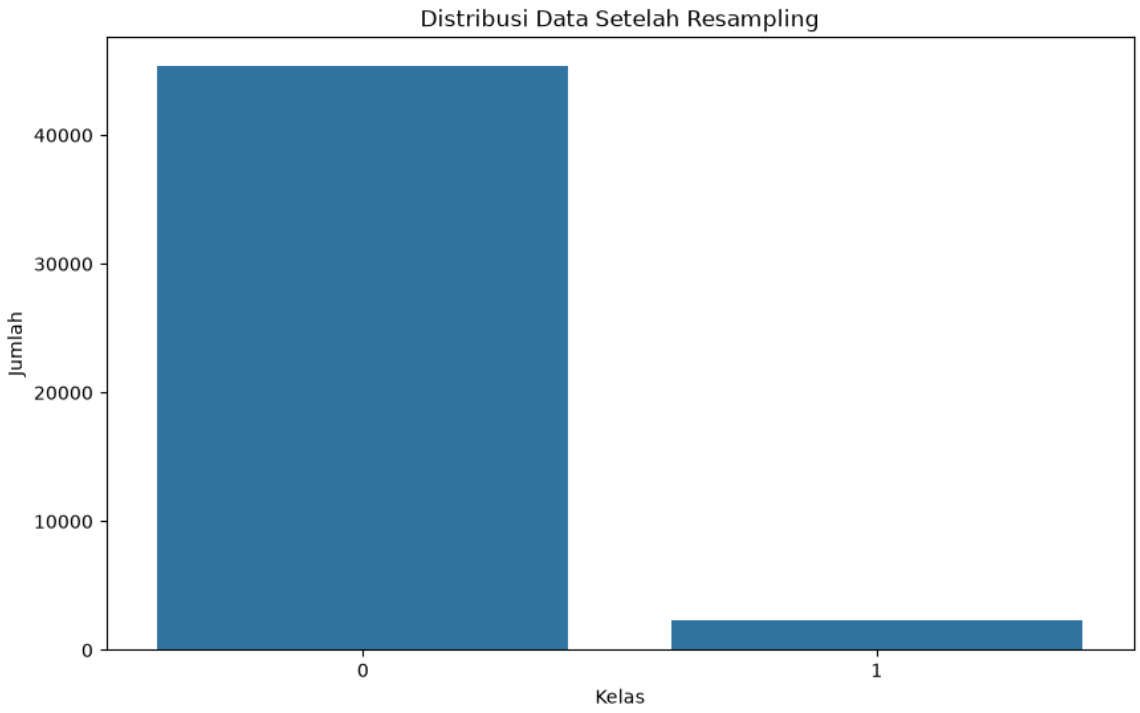
Tabel 1: Distribusi data kelas pada dataset

Kelas	Jumlah Data	Persentase
Class 0 (Normal)	283.253	99,83%
Class 1 (Fraud)	473	0,17%
Total	**283.726**	**100,00%**

Pendekatan yang Digunakan

Data dibagi menggunakan Stratified Train-Test Split dengan rasio 80:20 dan stratifikasi berdasarkan target Class (stratify=y). Tidak dilakukan tahap normalisasi dan feature engineering tambahan pada Fitur V1 hingga V28 karena data sudah berupa komponen utama hasil proyeksi PCA.

1. Teknik Resampling Data (Data-Level):
Untuk mengatasi ketimpangan kelas, pipeline resampling diterapkan pada data training:
a. SMOTE (sampling_strategy=0.01): Menambah sampel sintetis kelas 1 hingga mencapai proporsi 1% terhadap kelas 0.
b. Random Under-Sampler (sampling_strategy=0.1): Mengurangi sampel mayoritas kelas 0 hingga perbandingan akhir antara kelas 1 dan kelas 0 mencapai 1:10.



Gambar 2: Distribusi data training setelah resampling

2. Arsitektur Model Ensemble (Stacking Classifier):
Klasifikasi menggunakan Stacking Classifier dengan 5-fold cross-validation (cv=5):

a. Base Estimator: XGBoost (eval_metric='logloss'), CatBoost (verbose=0), dan LightGBM (verbose=-1).

b. Final Estimator: Logistic Regression untuk mengombinasikan prediksi probabilitas dari ketiga model pohon.

Tabel 2: Konfigurasi pipeline eksperimen

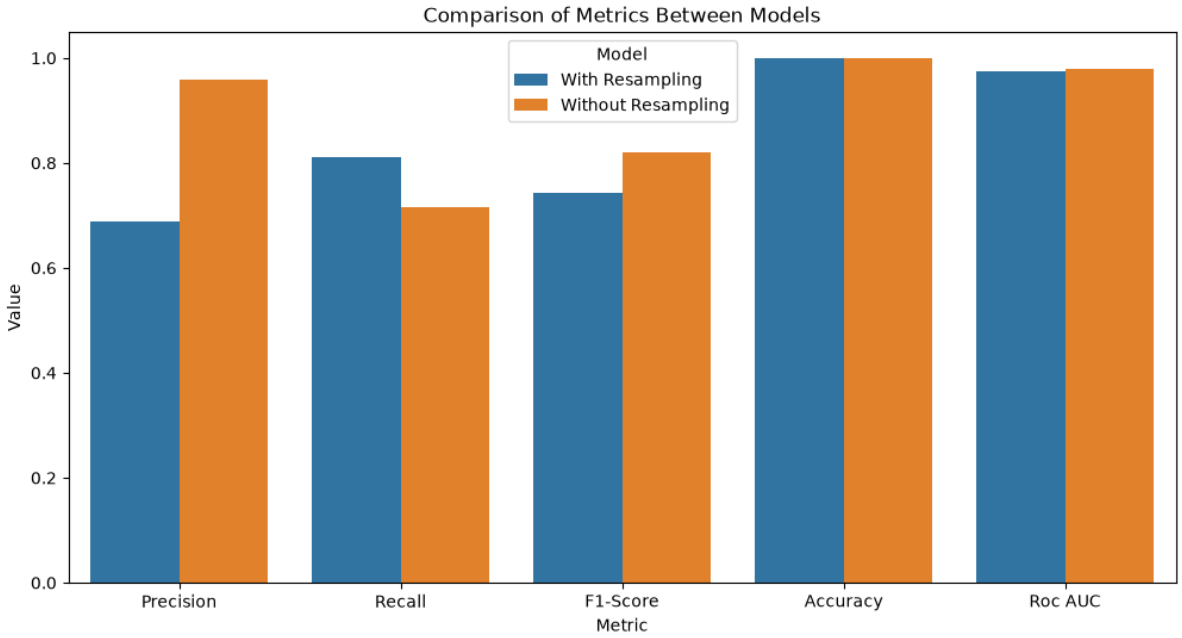
Pipeline	**Tahap Resampling**	**Estimator Klasifikasi**
With Resampling	SMOTE (0.01) + Random Under-Sampler (0.1)	Stacking (XGBoost, CatBoost, LightGBM -> Logistic Regression)
Without Resampling	Tanpa Resampling (Data Latih Asli)	Stacking (XGBoost, CatBoost, LightGBM -> Logistic Regression)

Hasil Evaluasi Model

Evaluasi performa model diuji pada data uji sebanyak 56.746 sampel (56.651 sampel kelas 0 dan 95 sampel kelas 1).

Tabel 3: Perbandingan metrik evaluasi model pada data uji

Model	**Precision**	**Recall**	**F1-Score**	**Accuracy**	**Roc AUC**
With Resampling	0,603	0,832	0,699	0,999	0,973
Without Resampling	0,986	0,758	0,857	1,000	0,971



Gambar 3: Perbandingan metrik evaluasi antara model dengan dan tanpa resampling

Perbandingan kinerja kedua model pada kelas minoritas (Class 1):
1. Recall: Model With Resampling mendeteksi 79 dari 95 kasus kelas 1 (Recall 0,832), sedangkan model Without Resampling mendeteksi 72 dari 95 kasus (Recall 0,758).
2. Precision & False Positive: Model Without Resampling hanya menghasilkan 1 False Positive (Precision 0,986). Sebaliknya, model With Resampling menghasilkan 52 False Positive yang menyebabkan nilai Precision turun menjadi 0,603.
3. F1-Score: Penurunan presisi yang tajam pada model With Resampling menyebabkan F1-Score turun ke angka 0,699, dibandingkan 0,857 pada model Without Resampling.
4. ROC AUC & Accuracy: Skor ROC AUC kedua model berada pada kisaran ~0,97 (0,973 vs 0,971) dan Accuracy sebesar ~0,999.

Kesimpulan

Berdasarkan hasil eksperimen perbandingan model Stacking Classifier (XGBoost + CatBoost + LightGBM) dengan dan tanpa teknik resampling:

1. **Trade-off Precision vs. Recall**:
    - **With Resampling (SMOTE + Random Under-Sampling)**: Menghasilkan Recall yang sedikit lebih tinggi (~81% vs ~72%), yang berarti mampu menjaring sedikit lebih banyak kasus fraud. Namun, pendekatan ini memicu lonjakan False Positive yang signifikan, menyebabkan Precision anjlok drastis dari **~96% ke ~69%**, serta menurunkan skor keseimbangan F1-Score menjadi **~0.74**.

- **Without Resampling (Data Asli)**: Menjaga jumlah False Positive tetap sangat minim, menghasilkan Precision yang sangat tinggi (**~96%**) dan F1-Score yang jauh lebih unggul (**~0.82**).

2. **Daya Pisah Model (ROC-AUC) Identik (~0.97)**:
    - Nilai ROC-AUC (~0.97) dan Accuracy (~0.99) pada kedua pendekatan bernilai hampir identik. Hal ini menunjukkan bahwa trio model gradient boosting yang digunakan secara alami sudah memiliki daya pisah fitur yang sangat kuat terhadap fraud. Resampling tidak meningkatkan kemampuan pemisahan model, melainkan hanya menggeser batas keputusan (decision threshold) menjadi lebih agresif.

Kesimpulan Akhir (*Takeaway*)

Tidak semua data imbalanced harus di-balance (Not all imbalanced data needs to be balanced).

Ketika menggunakan model ensemble pohon yang kuat (seperti gradient boosting) dengan fitur-fitur yang informatif, melatih model langsung pada data asli tanpa resampling terbukti menghasilkan performa yang jauh lebih stabil, presisi, dan realistis untuk diterapkan tanpa membanjiri sistem dengan alarm palsu pada transaksi nasabah normal.