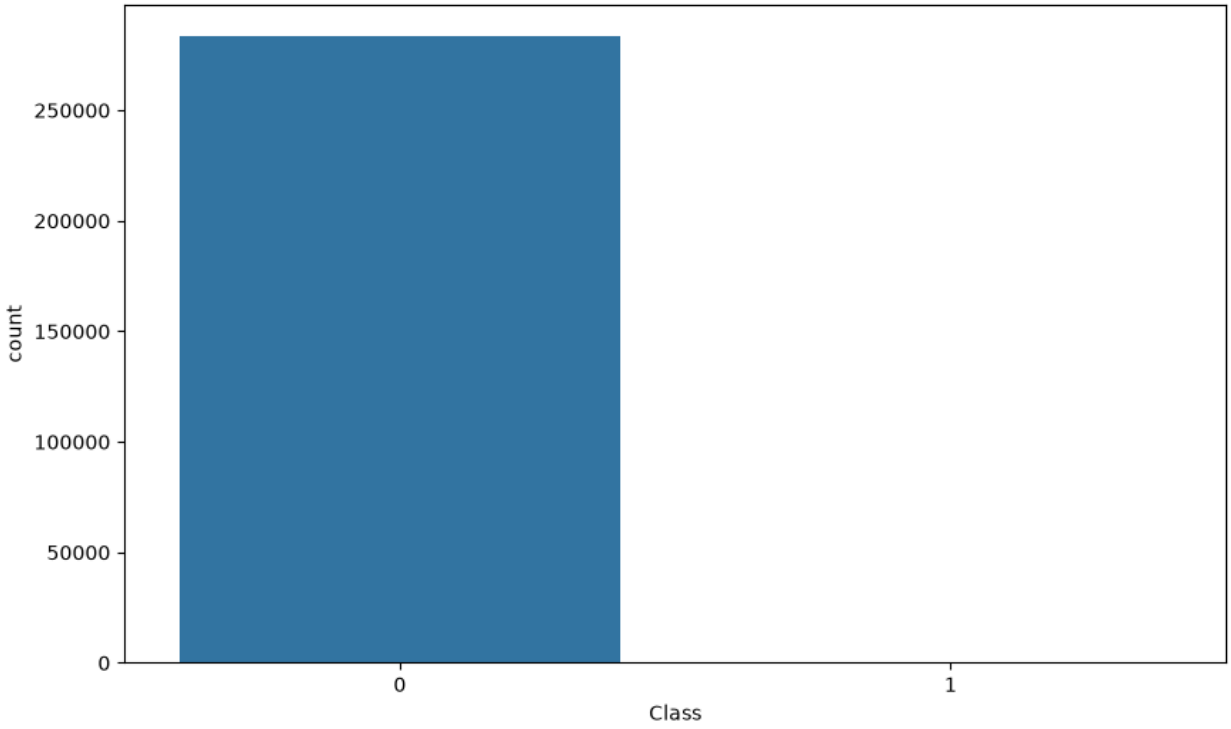
Tugas Praktikum 3: Classification dengan Ensemble Method & Class Imbalance

Nama : Fahmi Alfayadh
NRP : 5054251015

Distribusi Data



Gambar 1: Distribusi data class 1 dan 0

Dataset memiliki distribusi yang sangat timpang. Class 0 memiliki **283253** data dan class 1 hanya memiliki **473** data dengan perbandingan class 0 dan 1 adalah 1 :598. Bagi kebanyakan kasus, distribusi seperti ini merupakan kondisi yang perlu diperhatikan dan diperlukan strategi khusus untuk tahap modelling.

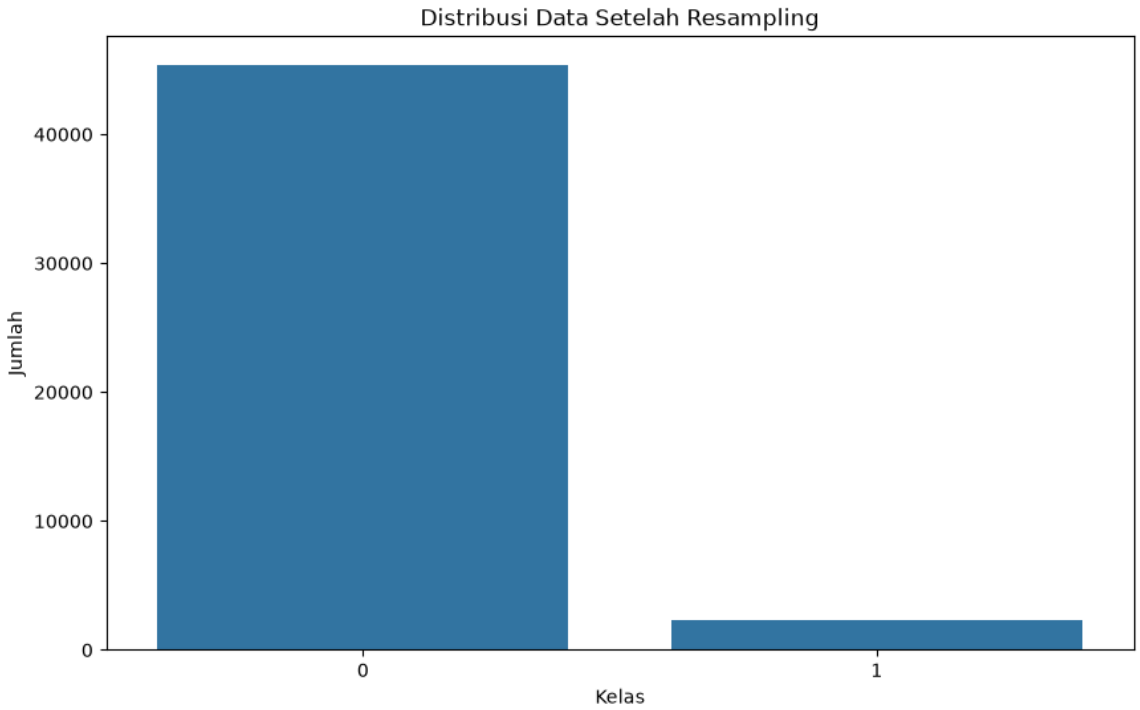
Tabel 1: Distribusi data kelas pada dataset

Kelas	Jumlah Data	Persentase
Class 0 (Normal)	283.253	99,83%
Class 1 (Fraud)	473	0,17%
Total	**283.726**	**100,00%**

Pendekatan yang Digunakan

Data dibagi menggunakan Stratified Train-Test Split dengan rasio 80:20 dan stratifikasi berdasarkan target Class (stratify=y). Tidak dilakukan tahap normalisasi dan feature engineering tambahan pada Fitur V1 hingga V28 karena data sudah berupa komponen utama hasil proyeksi PCA.

1. Teknik Resampling Data (Data-Level):
Untuk mengatasi ketimpangan kelas, pipeline resampling diterapkan pada data training:
a. SMOTE (sampling_strategy=0.01): Menambah sampel sintetis kelas 1 hingga mencapai proporsi 1% terhadap kelas 0.
b. Random Under-Sampler (sampling_strategy=0.1): Mengurangi sampel mayoritas kelas 0 hingga perbandingan akhir antara kelas 1 dan kelas 0 mencapai 1:10.



Gambar 2: Distribusi data training setelah resampling

2. Arsitektur Model Ensemble (Stacking Classifier):
Klasifikasi menggunakan Stacking Classifier dengan 5-fold cross-validation (cv=5):

a. Base Estimator: XGBoost (eval_metric='logloss'), CatBoost (verbose=0), dan LightGBM (verbose=-1).

b. Final Estimator: Logistic Regression untuk mengombinasikan prediksi probabilitas dari ketiga model pohon.

Tabel 2: Konfigurasi pipeline eksperimen

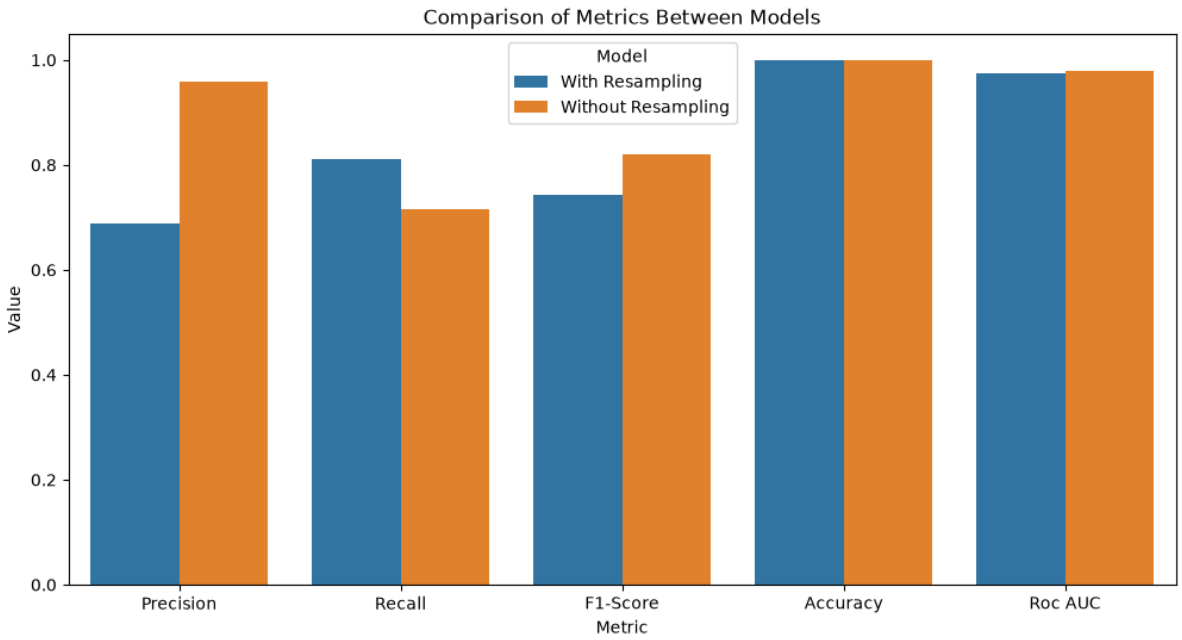
Pipeline	**Tahap Resampling**	**Estimator Klasifikasi**
With Resampling	SMOTE (0.01) + Random Under-Sampler (0.1)	Stacking (XGBoost, CatBoost, LightGBM -> Logistic Regression)
Without Resampling	Tanpa Resampling (Data Latih Asli)	Stacking (XGBoost, CatBoost, LightGBM -> Logistic Regression)

Hasil Evaluasi Model

Evaluasi performa model diuji pada data uji sebanyak 56.746 sampel (56.651 sampel kelas 0 dan 95 sampel kelas 1).

Tabel 3: Perbandingan metrik evaluasi model pada data uji

Model	**Precision**	**Recall**	**F1-Score**	**Accuracy**	**Roc AUC**
With Resampling	0,603	0,832	0,699	0,999	0,973
Without Resampling	0,986	0,758	0,857	1,000	0,971



Gambar 3: Perbandingan metrik evaluasi antara model dengan dan tanpa resampling

Perbandingan kinerja kedua model pada kelas minoritas (Class 1):
1. Recall: Model With Resampling mendeteksi 79 dari 95 kasus kelas 1 (Recall 0,832), sedangkan model Without Resampling mendeteksi 72 dari 95 kasus (Recall 0,758).
2. Precision & False Positive: Model Without Resampling hanya menghasilkan 1 False Positive (Precision 0,986). Sebaliknya, model With Resampling menghasilkan 52 False Positive yang menyebabkan nilai Precision turun menjadi 0,603.
3. F1-Score: Penurunan presisi yang tajam pada model With Resampling menyebabkan F1-Score turun ke angka 0,699, dibandingkan 0,857 pada model Without Resampling.
4. ROC AUC & Accuracy: Skor ROC AUC kedua model berada pada kisaran ~0,97 (0,973 vs 0,971) dan Accuracy sebesar ~0,999.

Kesimpulan

Berdasarkan perbandingan evaluasi model Stacking Classifier dengan dan tanpa teknik resampling:
1. Trade-off Precision vs Recall:
Pendekatan With Resampling (SMOTE + Random Under-Sampling) menghasilkan Recall lebih tinggi (0,832), namun diiringi lonjakan False Positive yang menurunkan Precision (0,603) dan F1-Score (0,699). Sebaliknya, pendekatan Without Resampling menghasilkan Precision (0,986) dan F1-Score (0,857) yang jauh lebih tinggi dengan jumlah False Positive yang sangat minim, meskipun nilai Recall berada di angka 0,758.

2. Daya Pisah Model (ROC AUC & Accuracy):
Metrik ROC AUC (~0,97) dan Accuracy (~0,99) pada kedua pendekatan bernilai hampir identik. Secara teori trio gradient boosting (XGBoost, CatBoost, LightGBM) memang memiliki kemampuan yang stabil dalam membedakan kelas target. Teknik resampling berperan menggeser ambang batas sensitivitas (decision threshold) ke arah yang lebih permisif terhadap kelas minoritas.

Berdasarkan keseluruhan metrik evaluasi pada eksperimen ini, pendekatan Without Resampling merupakan teknik yang lebih optimal. Meskipun penambahan SMOTE dan Random Under-Sampling memberikan peningkatan Recall sebesar 7,4% (dari 0,758 menjadi 0,832), konsekuensi penurunan Precision sebesar 38,3% (dari 0,986 menjadi 0,603) membuat skor keseimbangan F1-Score turun dari 0,857 menjadi 0,699. Dengan nilai ROC AUC yang setara di kisaran 0,97, model Stacking Classifier tanpa resampling menghasilkan performa klasifikasi yang jauh lebih stabil serta efisien karena meminimalkan False Positive pada data mayoritas tanpa kehilangan daya deteksi yang substansial.