Laporan Praktikum 2 Data Mining:
Preprocessing Dataset Ames Housing

Nama: Fahmi Alfayadh
NRP: 5054251015
Kelas: Data Mining (N)

1 Deskripsi Dataset

Dataset berisi transaksi properti residensial dengan 1 kolom identitas (Id), 79 fitur, dan 1 target (SalePrice). Pemeriksaan awal mencakup dimensi, tipe data, duplikasi, dan missing values.

Tabel 1. Parameter dataset awal (train.csv).

Parameter	Nilai
Jumlah baris	1.460
Jumlah kolom	81 (Id + 79 fitur + SalePrice)
Kolom numerik	38
Kolom kategorikal	43
Baris duplikat	0
Total missing values	7.829

2 Langkah Praproses dan Hasil Tiap Tahap

2.1 Penanganan Missing Values

Berdasarkan dokumentasi resmi dataset (data_description.txt), sebagian besar nilai NA pada fitur fasilitas properti merepresentasikan ketiadaan fasilitas, bukan data hilang akibat kesalahan input. Terdapat 19 kolom yang memiliki missing values.

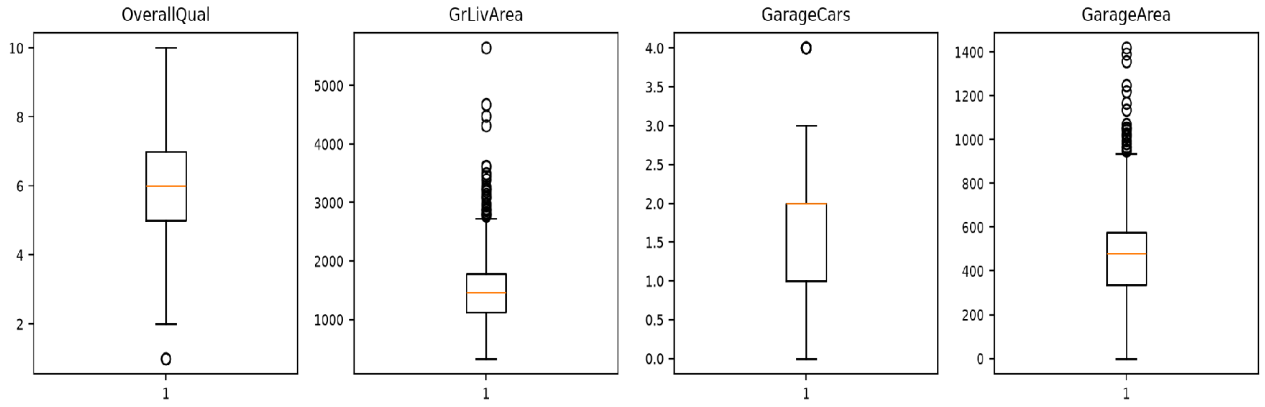
Tabel 2. Missing values per fitur dan penanganannya.

Fitur	Jumlah NA	%	Penanganan
PoolQC	1.453	99,5%	Diisi 'None' (NA = No Pool)
MiscFeature	1.406	96,3%	Diisi 'None' (NA = None)
Alley	1.369	93,8%	Diisi 'None' (NA = No alley access)
Fence	1.179	80,8%	Diisi 'None' (NA = No Fence)
MasVnrType	872	59,7%	Diisi 'None' (NA = None)
FireplaceQu	690	47,3%	Diisi 'None' (NA = No Fireplace)
LotFrontage	259	17,7%	Median per Neighborhood
GarageType / Finish / Qual / Cond	81	5,5%	Diisi 'None' (NA = No Garage)
GarageYrBlt	81	5,5%	Diisi YearBuilt
BsmtExposure / BsmtFinType2	38	2,6%	Diisi 'None' (NA = No Basement)
BsmtQual / BsmtCond / BsmtFinType1	37	2,5%	Diisi 'None' (NA = No Basement)
MasVnrArea	8	0,5%	Diisi 0 (tidak ada veneer)
Electrical	1	0,1%	Diisi modus (SBrkr)

Hasil: total missing values = 0.

2.2 Deteksi dan Penanganan Outlier

Deteksi menggunakan metode IQR pada seluruh fitur numerik (kecuali Id). Dari 37 fitur numerik, 32 fitur memiliki setidaknya satu data pencilan. Untuk visualisasi lebih lanjut dipilih 4 fitur dengan korelasi tertinggi terhadap SalePrice (Tabel 3, Gambar 1).

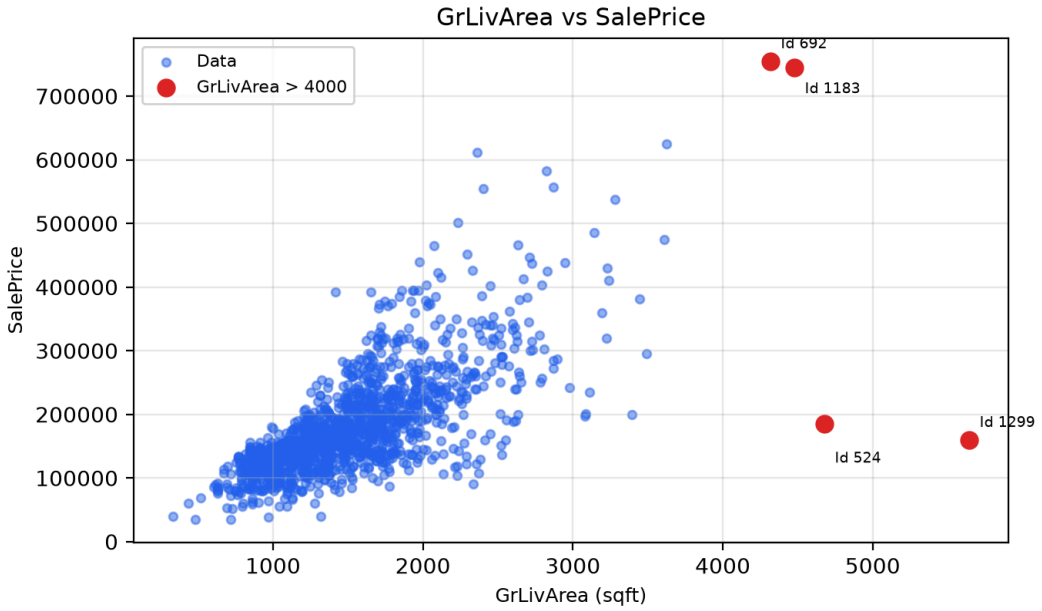


Gambar 1. Boxplot OverallQual, GrLivArea, GarageCars, dan GarageArea.

Tabel 3. Empat fitur korelasi tertinggi dan jumlah outlier IQR.

Fitur	Korelasi vs SalePrice	Outlier (IQR)
OverallQual	0,79	2
GrLivArea	0,71	31
GarageCars	0,64	5
GarageArea	0,62	21

Scatter plot GrLivArea vs SalePrice (Gambar 2) memperlihatkan empat baris dengan GrLivArea > 4.000. Dua di antaranya (Id 524 dan 1299) berada jauh dari pola umum, dengan luas besar dan harga di bawah 300.000, sehingga kedua baris tersebut dihapus.



Gambar 2. Scatter GrLivArea vs SalePrice; empat titik bertanda merah memiliki GrLivArea > 4.000.

Tabel 4. Empat baris dengan GrLivArea > 4.000.

Id	GrLivArea	SalePrice	OverallQual
524	4.676	184.750	10
692	4.316	755.000	10
1183	4.476	745.000	10
1299	5.642	160.000	10

Hasil: jumlah data setelah tahap ini = 1.458 baris (dari 1.460).

2.3 Encoding Fitur Kategorikal

Sebanyak 19 fitur ordinal dipetakan manual sesuai hierarki (contoh: Ex=5, Gd=4, TA=3, Fa=2, Po=1, None=0 untuk ExterQual, BsmtQual, KitchenQual, dan sejenisnya; GLQ=6 hingga None=0 untuk BsmtFinType1/2; Fin=3, RFn=2, Unf=1, None=0 untuk GarageFinish).

Sisa 24 fitur nominal (misalnya Neighborhood, MSZoning, SaleType) di-encode dengan LabelEncoder karena tidak membutuhkan urutan angka.

Hasil: seluruh kolom object terkonversi menjadi numerik; sisa kolom object = 0.

2.4 Normalisasi Fitur

Seluruh 79 fitur independen dinormalisasi ke rentang [0, 1] dengan MinMaxScaler. Kolom Id dan target SalePrice tidak dinormalisasi.

Hasil: rentang nilai fitur setelah normalisasi = [0,0, 1,0].

2.5 Seleksi Fitur

Seleksi fitur dilakukan setelah normalisasi pada 79 fitur dengan tiga kriteria:
variansi < 0,01 (VarianceThreshold), |korelasi| antar fitur > 0,9, dan |korelasi| ke SalePrice < 0,05.

Tabel 5. Kriteria seleksi fitur dan jumlah dihapus.

Kriteria	Dihapus	Keterangan
Variansi < 0,01	15	Hampir konstan pada data [0, 1]
|Korelasi| antar fitur > 0,9	2	GarageCond (pasangan GarageQual, r=0,959); PoolQC (pasangan PoolArea, r=0,932)
|Korelasi| ke SalePrice < 0,05	14	Contoh: MoSold, YrSold, Street, Utilities
Gabungan (unik)	23	79 → 56 fitur

Daftar 23 fitur yang dihapus:
3SsnPorch, BsmtFinSF2, BsmtFinType2, BsmtHalfBath, Condition2, ExterCond, GarageCond, Heating, KitchenAbvGr, LandContour, LotArea, LotFrontage, LowQualFinSF, MasVnrType, MiscFeature, MiscVal, MoSold, PoolArea, PoolQC, RoofMatl, Street, Utilities, YrSold.

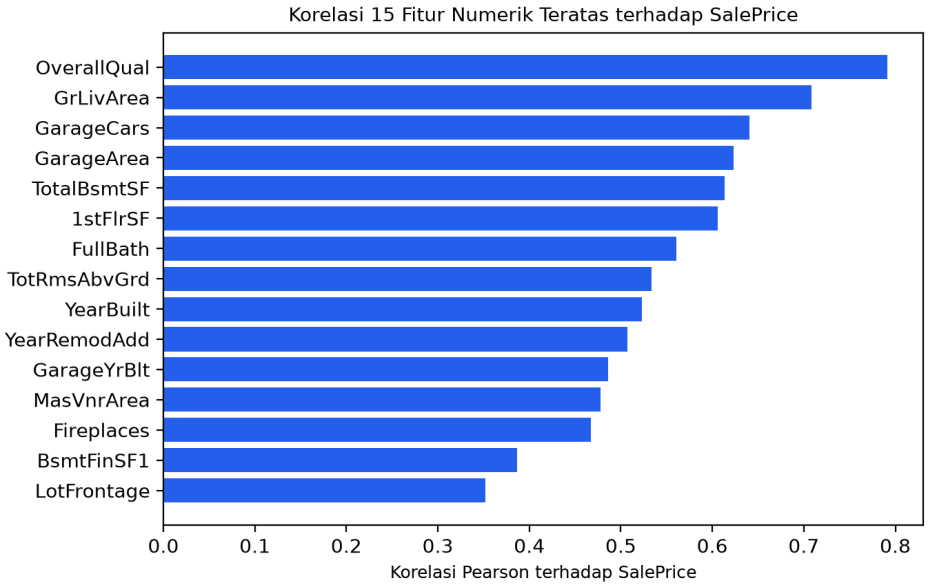
Tabel 6. Evaluasi Semua Fitur vs Fitur Terseleksi (Linear Regression, data uji 20%).

Skenario	Jumlah fitur	R^2 (uji)
Semua Fitur	79	0,8747
Fitur Terseleksi	56	0,8763

Hasil: R^2 naik dari 0,8747 menjadi 0,8763 dengan pengurangan 23 fitur (29,1%).

2.6 Reduksi Dimensi (PCA) dan Pengujian Baseline

PCA diuji pada dua basis, yaitu Semua Fitur (79) dan Fitur Terseleksi (56), masing-masing pada tiga ambang variansi kumulatif (95%, 90%, 80%). Linear Regression digunakan sebagai baseline dengan split 80:20 (random_state=42) untuk mencatat skor R^2 data uji pada tiap skenario. Korelasi fitur numerik terhadap target pada Gambar 3 memberi konteks dependensi linear yang dimanfaatkan model tersebut.



Gambar 3. Lima belas fitur numerik dengan korelasi tertinggi terhadap SalePrice.

Tabel 7. Skenario PCA pada dua basis dan skor R^2.

Basis	Skenario	Jumlah fitur	R^2 (uji)
Semua	Tanpa PCA	79	0,8747
Semua	PCA 95%	45	0,8486
Semua	PCA 90%	33	0,8357
Semua	PCA 80%	23	0,8246
Terseleksi	Tanpa PCA	56	0,8763
Terseleksi	PCA 95%	35	0,8549
Terseleksi	PCA 90%	27	0,8437
Terseleksi	PCA 80%	18	0,8268

Pada kedua basis, menurunkan ambang variansi PCA menurunkan jumlah fitur dan skor R^2. Basis Terseleksi tanpa PCA (56 fitur, R^2 0,8763) sedikit di atas Semua Fitur tanpa PCA (79 fitur, R^2 0,8747). PCA 95% dari basis Terseleksi (35 fitur, R^2 0,8549) berada di atas PCA 95% dari basis Semua (45 fitur, R^2 0,8486) dengan fitur lebih sedikit.

3 Ringkasan Dataset Akhir dan Kesimpulan

Tabel 8. Perbandingan sebelum dan setelah praproses.

Parameter	Sebelum	Setelah
Jumlah baris	1.460	1.458
Jumlah kolom	81	58 (Id + 56 fitur + SalePrice)
Kolom bertipe object	43	0
Total missing values	7.829	0
Baris duplikat	0	0
Rentang fitur independen	Bervariasi	[0, 1]
Dimensi fitur (terseleksi / PCA 90% dari terseleksi)	79	56 / 27

Tahapan praproses pada dataset Ames Housing meliputi penanganan missing values pada 19 kolom, penghapusan 2 baris outlier ekstrem, encoding 43 fitur kategorikal, normalisasi 79 fitur ke rentang [0, 1], dan seleksi fitur menjadi 56 fitur (23 fitur dihapus). Evaluasi Linear Regression menunjukkan R^2 0,8747 untuk Semua Fitur dan 0,8763 untuk Fitur Terseleksi. PCA diuji pada kedua basis: PCA 95% dari basis Terseleksi (35 fitur, R^2 0,8549) mengungguli PCA 95% dari basis Semua (45 fitur, R^2 0,8486), sedangkan ambang 90% dan 80% menurunkan skor lebih lanjut.

Dataset akhir terdiri dari 1.458 baris dan 58 kolom (Id + 56 fitur terseleksi + SalePrice) dengan seluruh fitur bertipe numerik dan tanpa missing values. Dataset ini siap digunakan untuk tahap pemodelan.