Laporan Praktikum 2 Data Mining:
Preprocessing Dataset Ames Housing

Nama: Fahmi Alfayadh
NRP: 5054251015
Kelas: Data Mining (N)

1 Deskripsi Dataset

Dataset berisi transaksi properti residensial dengan 1 kolom identitas (Id), 79 fitur, dan 1 target (SalePrice). Pemeriksaan awal mencakup dimensi, tipe data, duplikasi, dan missing values.

Tabel 1. Parameter dataset awal (train.csv).

Parameter	Nilai
Jumlah baris	1.460
Jumlah kolom	81 (Id + 79 fitur + SalePrice)
Kolom numerik	38
Kolom kategorikal	43
Baris duplikat	0
Total missing values	7.829

2 Langkah Praproses dan Hasil Tiap Tahap

2.1 Penanganan Missing Values

Berdasarkan dokumentasi resmi dataset (data_description.txt), sebagian besar nilai NA pada fitur fasilitas properti merepresentasikan ketiadaan fasilitas, bukan data hilang akibat kesalahan input. Terdapat 19 kolom yang memiliki missing values.

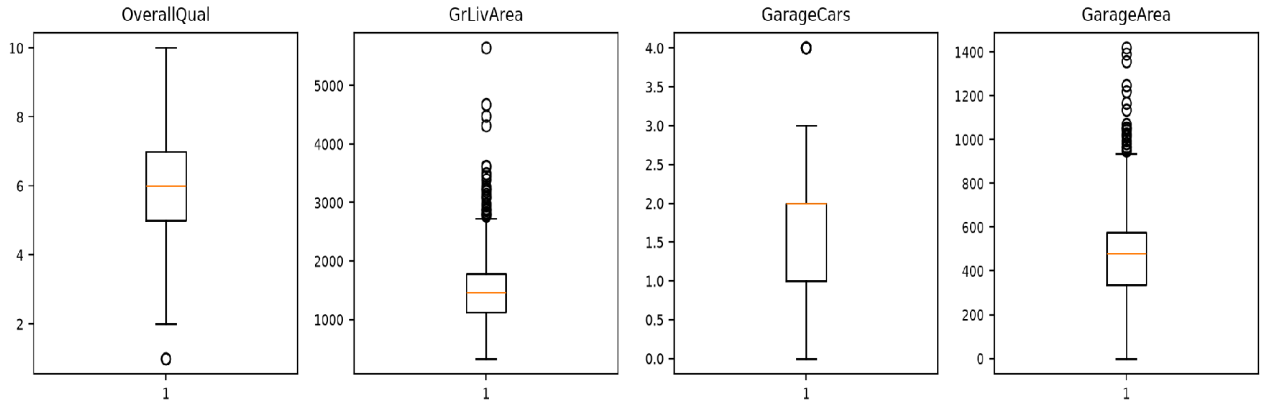
Tabel 2. Missing values per fitur dan penanganannya.

Fitur	Jumlah NA	%	Penanganan
PoolQC	1.453	99,5%	Diisi 'None' (NA = No Pool)
MiscFeature	1.406	96,3%	Diisi 'None' (NA = None)
Alley	1.369	93,8%	Diisi 'None' (NA = No alley access)
Fence	1.179	80,8%	Diisi 'None' (NA = No Fence)
MasVnrType	872	59,7%	Diisi 'None' (NA = None)
FireplaceQu	690	47,3%	Diisi 'None' (NA = No Fireplace)
LotFrontage	259	17,7%	Median per Neighborhood
GarageType / Finish / Qual / Cond	81	5,5%	Diisi 'None' (NA = No Garage)
GarageYrBlt	81	5,5%	Diisi YearBuilt
BsmtExposure / BsmtFinType2	38	2,6%	Diisi 'None' (NA = No Basement)
BsmtQual / BsmtCond / BsmtFinType1	37	2,5%	Diisi 'None' (NA = No Basement)
MasVnrArea	8	0,5%	Diisi 0 (tidak ada veneer)
Electrical	1	0,1%	Diisi modus (SBrkr)

Hasil: total missing values = 0.

2.2 Deteksi dan Penanganan Outlier

Deteksi menggunakan metode IQR pada seluruh fitur numerik (kecuali Id). Dari 37 fitur numerik, 32 fitur memiliki setidaknya satu data pencilan. Untuk visualisasi lebih lanjut dipilih 4 fitur dengan korelasi tertinggi terhadap SalePrice (Tabel 3, Gambar 1).

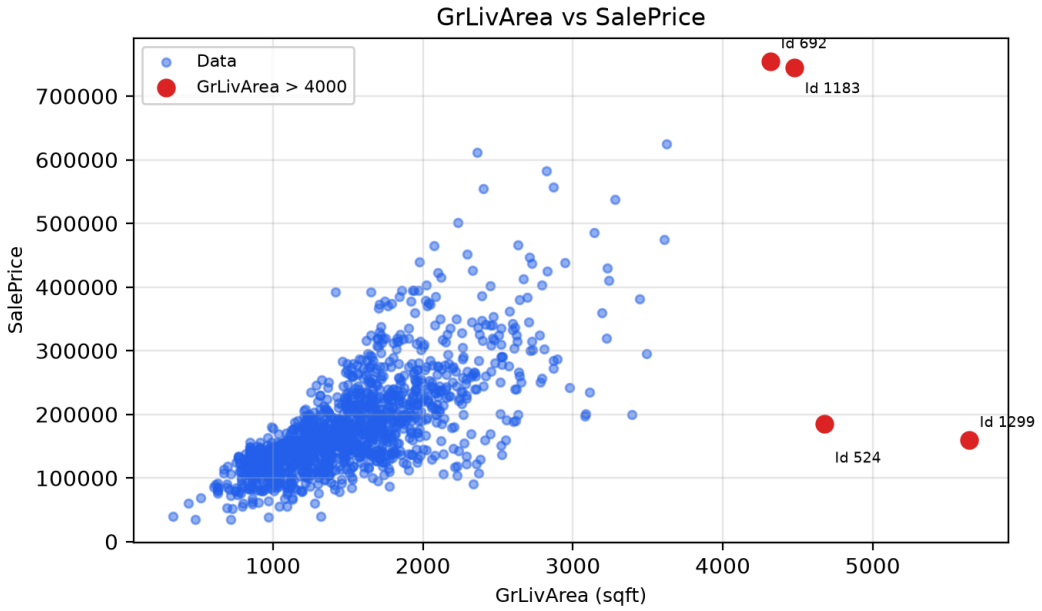


Gambar 1. Boxplot OverallQual, GrLivArea, GarageCars, dan GarageArea.

Tabel 3. Empat fitur korelasi tertinggi dan jumlah outlier IQR.

Fitur	Korelasi vs SalePrice	Outlier (IQR)
OverallQual	0,79	2
GrLivArea	0,71	31
GarageCars	0,64	5
GarageArea	0,62	21

Scatter plot GrLivArea vs SalePrice (Gambar 2) memperlihatkan empat baris dengan GrLivArea > 4.000. Dua di antaranya (Id 524 dan 1299) berada jauh dari pola umum, dengan luas besar dan harga di bawah 300.000, sehingga kedua baris tersebut dihapus.



Gambar 2. Scatter GrLivArea vs SalePrice; empat titik bertanda merah memiliki GrLivArea > 4.000.

Tabel 4. Empat baris dengan GrLivArea > 4.000.

Id	GrLivArea	SalePrice	OverallQual
524	4.676	184.750	10
692	4.316	755.000	10
1183	4.476	745.000	10
1299	5.642	160.000	10

Hasil: jumlah data setelah tahap ini = 1.458 baris (dari 1.460).

2.3 Encoding Fitur Kategorikal

Sebanyak 19 fitur ordinal dipetakan manual sesuai hierarki (contoh: Ex=5, Gd=4, TA=3, Fa=2, Po=1, None=0 untuk ExterQual, BsmtQual, KitchenQual, dan sejenisnya; GLQ=6 hingga None=0 untuk BsmtFinType1/2; Fin=3, RFn=2, Unf=1, None=0 untuk GarageFinish).

Sisa 24 fitur nominal (misalnya Neighborhood, MSZoning, SaleType) di-encode dengan LabelEncoder karena tidak membutuhkan urutan angka.

Hasil: seluruh kolom object terkonversi menjadi numerik; sisa kolom object = 0.

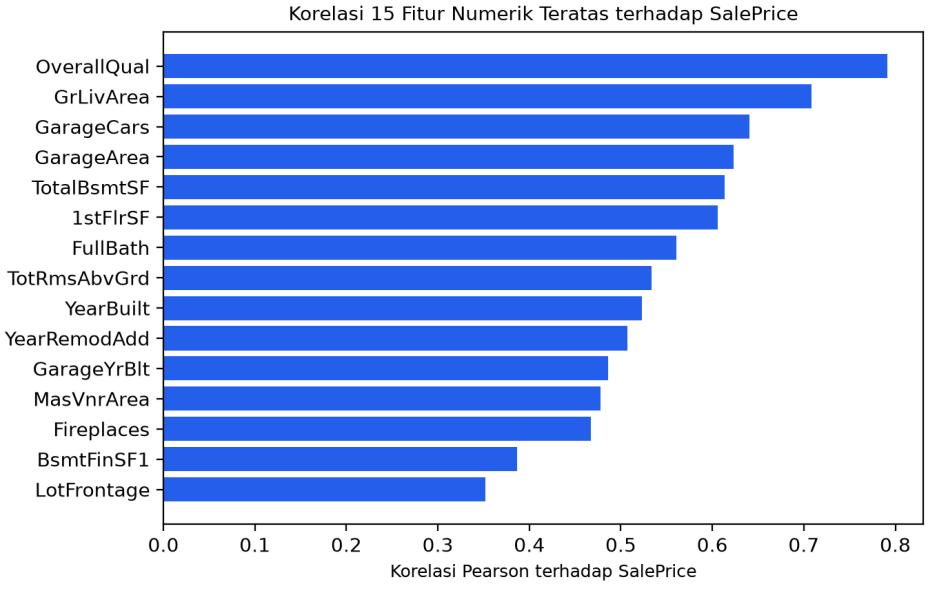
2.4 Normalisasi Fitur

Seluruh 79 fitur independen dinormalisasi ke rentang [0, 1] dengan MinMaxScaler. Kolom Id dan target SalePrice tidak dinormalisasi.

Hasil: rentang nilai fitur setelah normalisasi = [0,0, 1,0].

2.5 Reduksi Dimensi (PCA) dan Pengujian Baseline

PCA diuji pada tiga ambang variansi kumulatif. Linear Regression digunakan sebagai baseline dengan split 80:20 (random_state=42) untuk mencatat skor R^2 data uji pada tiap skenario. Korelasi fitur numerik terhadap target pada Gambar 3 memberi konteks dependensi linear yang dimanfaatkan model tersebut.



Gambar 3. Lima belas fitur numerik dengan korelasi tertinggi terhadap SalePrice.

Tabel 5. Skenario PCA dan skor R² baseline.

Skenario	Jumlah fitur	Reduksi	R² (uji)	Selisih	Fit Time (S_
Tanpa PCA	79	0%	0,8747	Baseline	0.0722
PCA 95%	45	43%	0,8486	−0,0261	0.1556
PCA 90%	33	58%	0,8357	−0,0390	0.1007
PCA 80%	23	71%	0,8246	−0,0501	0.0648

Menurunnya variansi fitur yang dipertahankan dibarengi dengan menurunnya skor R^2 serta waktu komputasi (Fit Time).

3 Ringkasan Dataset Akhir dan Kesimpulan

Tabel 6. Perbandingan sebelum dan setelah praproses.

Parameter	Sebelum	Setelah
Jumlah baris	1.460	1.458
Jumlah kolom	81	81
Kolom bertipe object	43	0
Total missing values	7.829	0
Baris duplikat	0	0
Rentang fitur independen	Bervariasi	[0, 1]
Dimensi fitur (skenario PCA 90%)	79	33

Tahapan pra proses yang dilakukan pada dataset Ames Housing meliputi penanganan missing values pada 19 kolom, deteksi dan penghapusan outlier ekstrem, encoding 43 fitur kategorikal, serta normalisasi fitur ke rentang [0, 1]. PCA dilakukan dengan opsi 95%, 90%, dan 80%. Evaluasi reduksi dimensi PCA menggunakan model Linear Regression menunjukkan bahwa pemangkasan fitur dari 79 menjadi 33 (PCA 90%) menghasilkan penurunan skor R² sebesar 0,039 dari baseline dibarengi dengan turunnya waktu, sementara PCA 80% dengan 23 fitur mengalami penurunan sebesar 0,050. Namun, waktu komputasi (fit time) juga menurun seiring berkurangnya variansi yang dipertahankan pada PCA.

Dataset akhir terdiri dari 1.458 baris dengan seluruh fitur bertipe numerik dan tanpa missing values. Dataset ini siap digunakan untuk tahapan berikutnya.