Praktikum 1 Web Scrapping

Nama: Fahmi Alfayadh
NRP: 5054251015

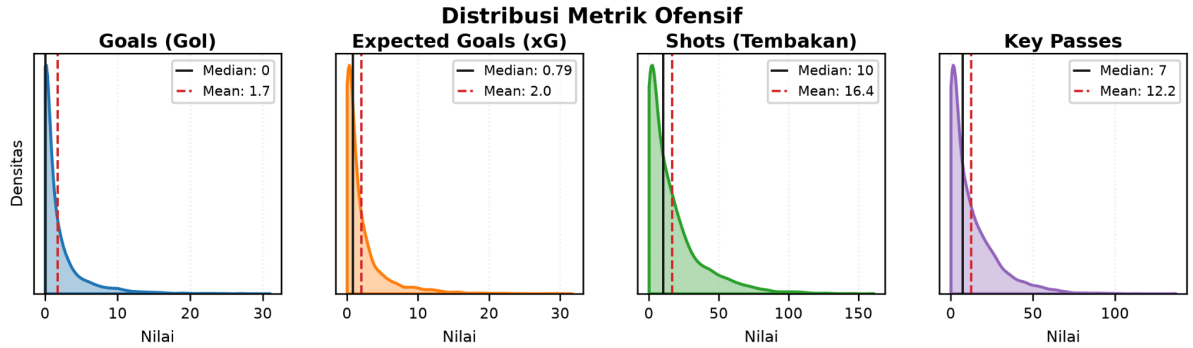
Kelas: Data Mining (N)

Deskripsi Dataset:

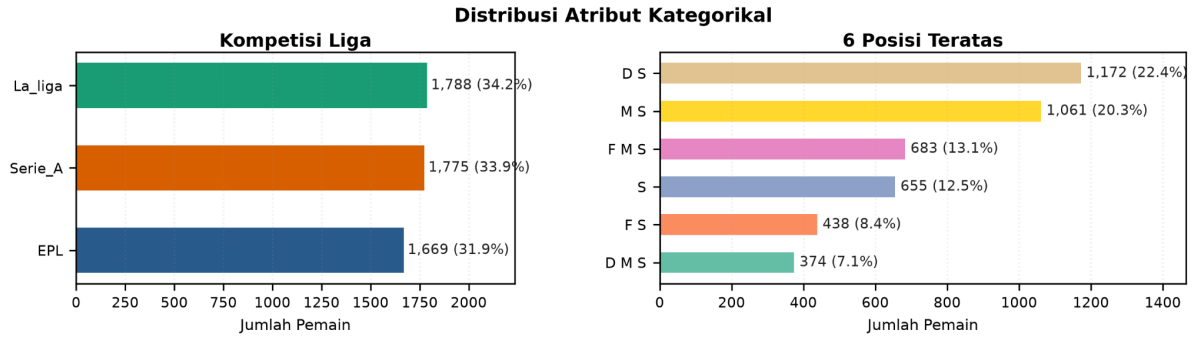
Dataset diperoleh melalui *web scraping* dari endpoint AJAX internal Understat menggunakan library **requests** (HTTP GET dengan header X-Requested-With: XMLHttpRequest). Respons berupa **JSON** murni sehingga tidak memerlukan HTML parser seperti BeautifulSoup. Data diolah dengan pandas dan disimpan ke CSV.

- **Cakupan:** 3 liga (EPL, La Liga, Serie A), 3 musim (2023/2024 s.d. 2025/2026).
- **Match per liga per musim:** 380 Match
- **Total:** 5.232 baris, 2.812 pemain unik, 213 klub, 19 atribut mentah + 8 atribut turunan.
- **Atribut utama:** identitas pemain (player_name, team_title, position, league), partisipasi (games, time), produktivitas (goals, xG, npg, npxG, assists, xA), volume (shots, key_passes), disiplin (yellow_cards, red_cards), dan kontribusi rantai serangan (xGChain, xGBuildup).

Statistik Deskriptif



Distribusi metrik ofensif menceng ke kanan (*right-skewed*): mayoritas pemain bernilai rendah, sedikit pemain dengan skill tinggi.



Distribusi liga seimbang (~32-34% masing-masing). Posisi terbanyak adalah D S (bek cadangan, 1.172) dan M S (gelandang cadangan, 1.061).

Penanganan Data

- Missing Values: 0 nilai hilang di seluruh kolom. Understat mengisi aksi yang tidak tercatat dengan nilai 0.
- **Outlier:** Nilai ekstrem (Contoh: Haaland 31,65 xG) merupakan representasi performa elite yang valid, bukan error, sehingga tidak dihapus.

	player_name	season	team_title	xG
0	Erling Haaland	2023/2024	Manchester City	31.653997
2320	Kylian Mbappe-Lottin	2024/2025	Real Madrid	30.135636
2321	Robert Lewandowski	2024/2025	Barcelona	29.414339
3509	Erling Haaland	2025/2026	Manchester City	28.795336
1758	Mohamed Salah	2024/2025	Liverpool	27.706267
4046	Kylian Mbappe-Lottin	2025/2026	Real Madrid	25.796529

Gambar diatas adalah pemain yg berada di quantile 0.999 (0.1%) pada feature xG. Isinya pemain-pemain terkenal yang wajar ada di interval tersebut.

	player_name	season	team_title	xGChain
1758	Mohamed Salah	2024/2025	Liverpool	48.535889
2325	Raphinha	2024/2025	Barcelona	39.282579
2320	Kylian Mbappe-Lottin	2024/2025	Real Madrid	38.313464
2345	Lamine Yamal	2024/2025	Barcelona	38.307875
4051	Lamine Yamal	2025/2026	Barcelona	33.655128
3509	Erling Haaland	2025/2026	Manchester City	32.735353

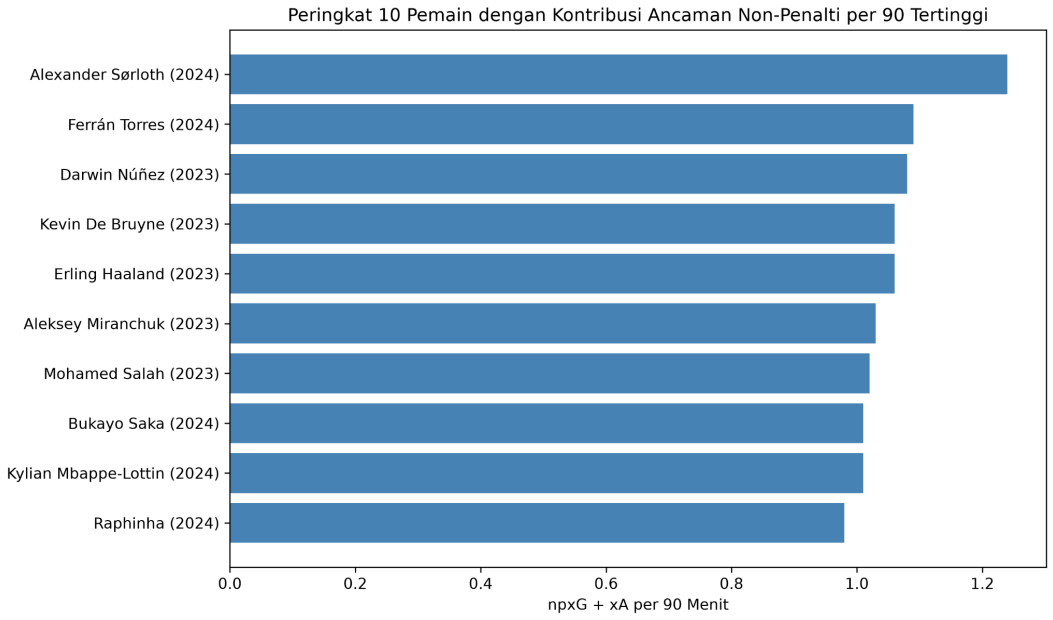
Gambar diatas adalah pemain yg berada di quantile 0.999 (0.1%) pada feature xGChain. Isinya juga pemain-pemain terkenal yang wajar ada di interval tersebut.

Langkah yang diambil:

- Filter time ≥ 900 menit untuk mengeliminasi noise statistik dari pemain dengan menit bermain sangat sedikit.
- Normalisasi metrik per 90 menit agar pemain dengan durasi bermain berbeda dapat diperbandingkan secara adil.
- Filter minimum 30 tembakan saat menghitung rasio xG/shots untuk menghindari bias sampel kecil.

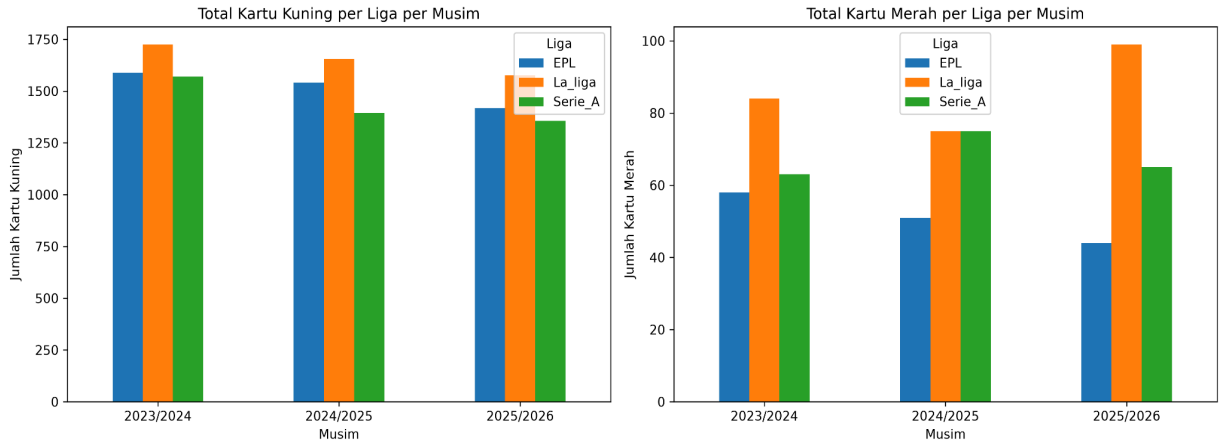
Visualisasi & Interpretasi

A. Top 10 Pemain dengan Ancaman Non-Penalti per 90 Menit

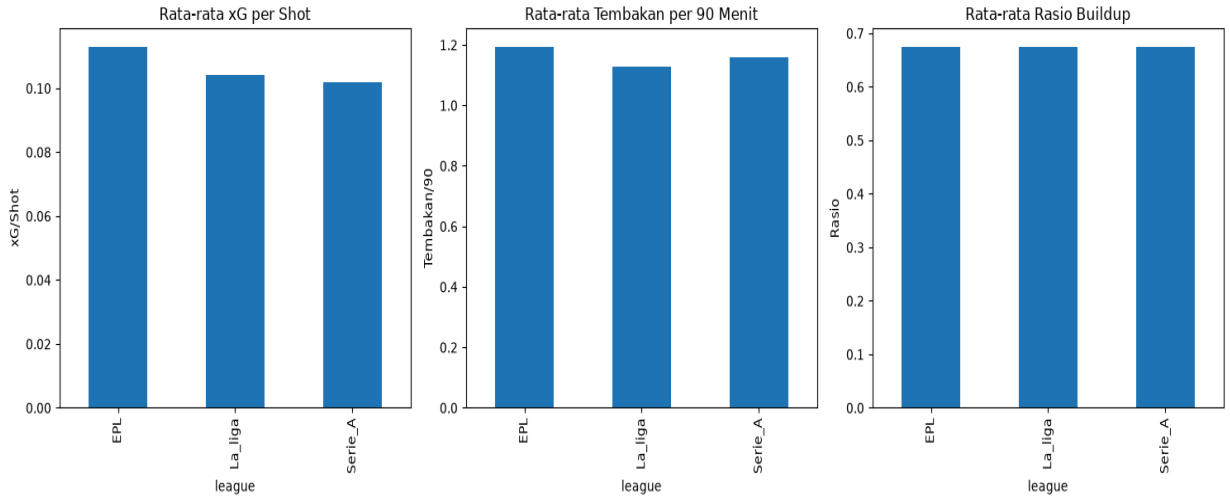


Normalisasi per 90 menit mengungkap pemain rotasi berefisiensi tinggi: Alexander Sorloth (2024) mencatat 1,24 npxG + xA/90 meski hanya bermain 1.525 menit. Disusul dengan Ferran Torres (2024) dan Darwin Nunez (2023)

B. Disiplin tiap liga

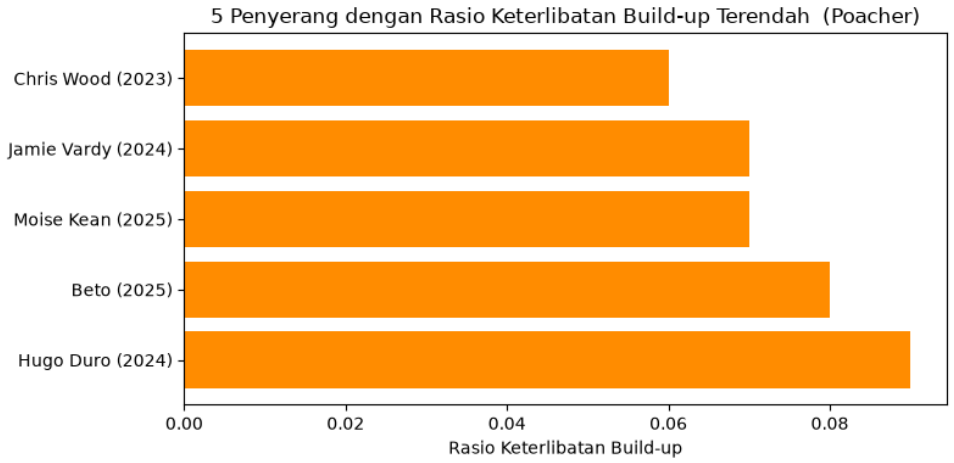


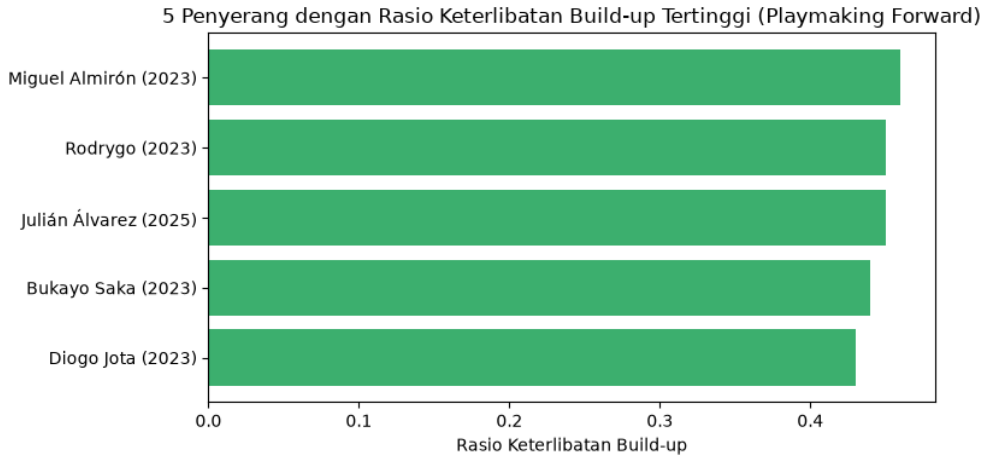
La Liga konsisten mencatat kartu terbanyak (puncak 99 kartu merah musim 2025/2026), jauh di atas EPL (44) dan Serie A (65).



EPL mencatat kualitas tembakan tertinggi (0,113 xG/shot) dan juga rata-rata tembakan per menit. Rata-rata rasio build up tiap liga memiliki nilai yang sama.

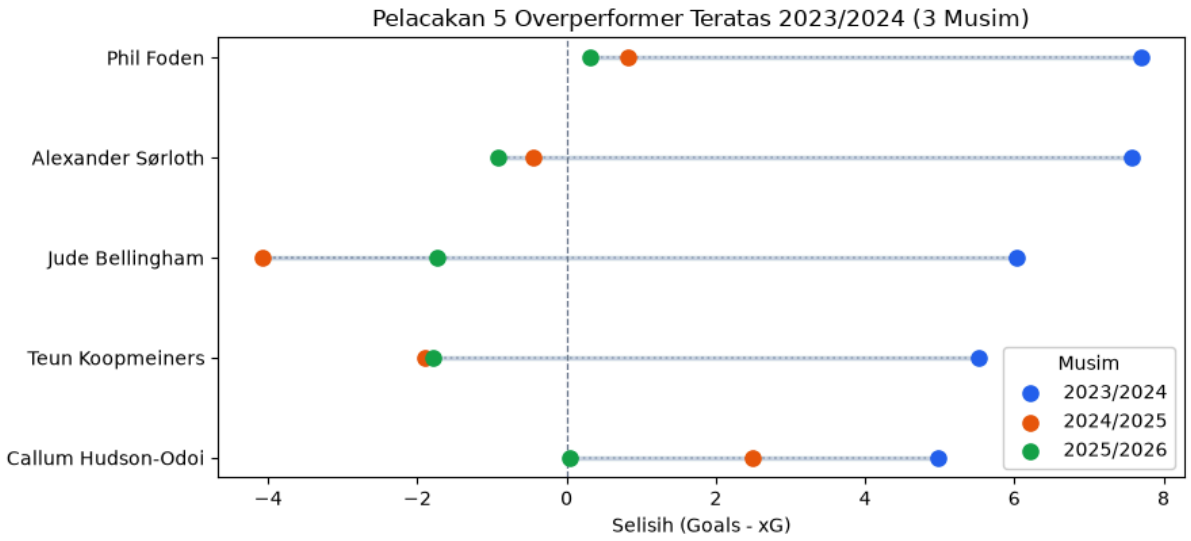
C. Profil Penyerang (Buildup vs Chain)





Dari hasil analisis ada 2 tipe penyerang: yang jarang dalam build up dan yang rajin dalam build up. beberapa playmaking forward adalah winger (Rodrygo, Saka, dan Almiron). Hal ini berasal dari keterbatasan data yang tidak menyediakan opsi winger dalam atribut posisi.

D. Overpeformance Player



Player di atas adalah mereka yang memiliki performa tinggi di suatu musim, namun menurun di musim-musim lainnya. Mayoritas dari mereka memiliki trend performa (Goals - xG) menurun tiap musimnya, Phil Foden saat 2023/2024 memiliki selisih (Goals - xG) sangat tinggi yang menandakan performa musim yang bagus, namun di next season menurun drastis kembali ke daerah 0.