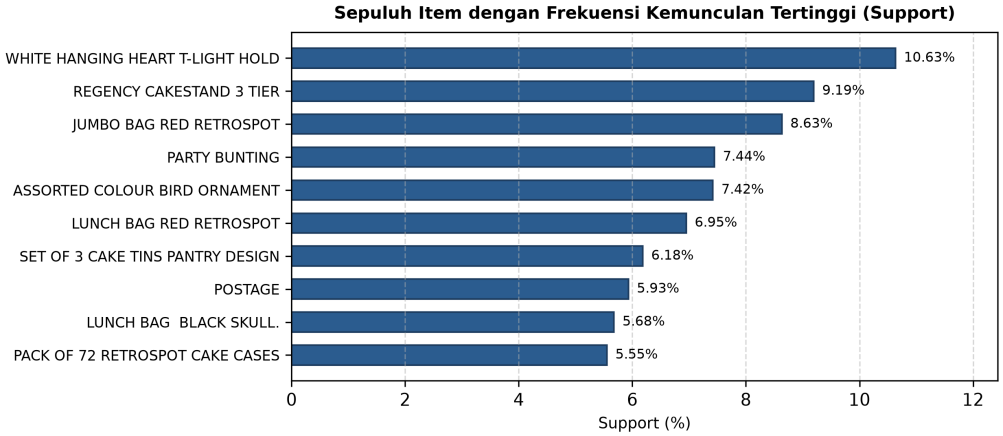
Tugas Praktikum 4: Association Rule Mining dengan Algoritma Apriori & FP-Growth

Nama : Fahmi Alfayadh
NRP : 5054251015

Distribusi Data

Gambar 1: Sepuluh item produk dengan frekuensi kemunculan tertinggi (Support)



Dataset Online Retail mencakup 541.909 baris transaksi ritel daring internasional. Tahap awal praproses dilakukan untuk memastikan kualitas data: eliminasi missing values pada Description (1.454 data) dan CustomerID (135.080 data), pemfilteran transaksi pembatalan berkode awalan 'C' pada InvoiceNo (9.291 data pembatalan), serta pembersihan 10.147 baris data duplikat. Diperoleh 392.732 baris data valid yang kemudian di-reshape menjadi 18.536 keranjang transaksi unik dengan 3.877 item produk unik. Rata-rata transaksi memuat 21,19 produk (median 15 produk, rentang 1-542 produk).

Tabel 1: Ringkasan statistik data sebelum dan setelah tahap praproses

Parameter	Data Awal (Mentah)	Data Setelah Praproses
Total Baris Data	541.909	392.732
Missing Values (Description)	1.454	0
Transaksi Pembatalan (Invoice C)	9.291	0
Baris Duplikat	10.147	0
Jumlah Transaksi Unik (InvoiceNo)	25.900	18.536
Jumlah Item Produk Unik	4.223	3.877
Rata-rata Produk per Transaksi	**20,92**	**21,19**

Pendekatan yang Digunakan

Data keranjang transaksi ditransformasikan menjadi matriks biner (One-Hot Encoded) berukuran 18.536 x 3.877 menggunakan TransactionEncoder. Dua algoritma association rule mining diterapkan dan dibandingkan secara komparatif:

1. Algoritma Apriori (Candidate Generation & Pruning): Mengekstraksi frequent itemset secara bertahap tingkat demi tingkat (level-wise). Kandidat itemset k dibentuk dari kombinasi k-1 dan dipangkas menggunakan prinsip downward closure (Apriori Property). Parameter low_memory=False digunakan untuk efisiensi komputasi.

2. Algoritma FP-Growth (Frequent Pattern Growth): Memadatkan transaksi ke dalam struktur pohon prefiks (FP-Tree). Algoritma mengekstraksi frequent itemset secara rekursif melalui conditional pattern base tanpa pembangkitan kandidat kombinasi secara eksplisit.

3. Parameter Mining & Threshold Aturan: Pengujian sensitivitas dilakukan pada rentang min_support = 0,010 hingga 0,050. Penyaringan aturan asosiasi menggunakan metrik confidence dengan batas ambang minimum min_threshold = 0,60 (60%).

Tabel 2: Konfigurasi pipeline eksperimen association rule mining

Pipeline	Representasi Data	Algoritma Mining & Threshold
Apriori Mining	Matriks Biner (18.536 x 3.877)	Apriori (Level-wise Pruning) | min_support = 0.02, min_confidence = 0.60
FP-Growth Mining	Matriks Biner (18.536 x 3.877)	FP-Growth (Tree Pattern Growth) | min_support = 0.02, min_confidence = 0.60

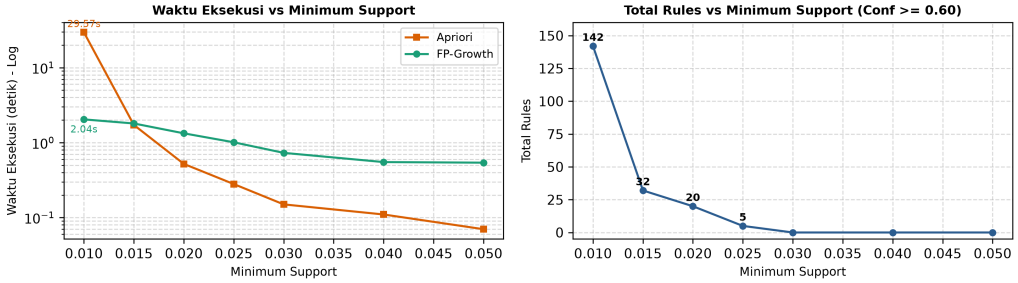
Hasil Evaluasi Model

Pengujian komparatif dilakukan terhadap 7 variasi threshold minimum support (0,010 hingga 0,050) untuk mengukur waktu komputasi, jumlah frequent itemset yang dihasilkan, dan jumlah association rules pada batas confidence 0,60.

Tabel 3: Perbandingan waktu komputasi dan hasil mining Apriori vs FP-Growth

Min Support	Frequent Itemsets	Total Rules (Conf >= 0.6)	Waktu Apriori	Waktu FP-Growth
0,010 (1,0%)	973	142	29,57 s	2,04 s
0,015 (1,5%)	440	32	1,72 s	1,80 s
0,020 (2,0%)	243	20	0,52 s	1,33 s
0,025 (2,5%)	147	5	0,28 s	1,01 s
0,030 (3,0%)	90	0	0,15 s	0,73 s
0,040 (4,0%)	42	0	0,11 s	0,55 s
0,050 (5,0%)	17	0	0,07 s	0,54 s

Gambar 2: Perbandingan waktu eksekusi dan total rules antara Apriori dan FP-Growth



Perbandingan kinerja komputasi dan karakteristik kedua algoritma:

1. Kesetaraan Hasil: Apriori dan FP-Growth menghasilkan 100% himpunan frequent itemsets dan association rules yang identik.
2. Skalabilitas pada Support Rendah: Pada min_support = 0,010, FP-Growth unggul signifikan (2,04 s vs 29,57 s, ~14,5x lebih cepat) karena mengeliminasi tahap pembangkitan kandidat kombinasi (candidate generation).
3. Karakteristik pada Support Tinggi: Pada min_support >= 0,020, itemset yang lolos menyusut tajam sehingga overhead inisialisasi FP-Tree membuat Apriori sedikit lebih cepat (0,52 s vs 1,33 s).
4. Sensitivitas Minimum Support: Pada min_support >= 0,030, tidak ada aturan asosiasi yang terbentuk pada threshold confidence 0,60 (0 rules). Nilai min_support = 0,020 menghasilkan 20 aturan asosiasi yang terarah dan bermakna.

Analisis Association Rules Terpilih

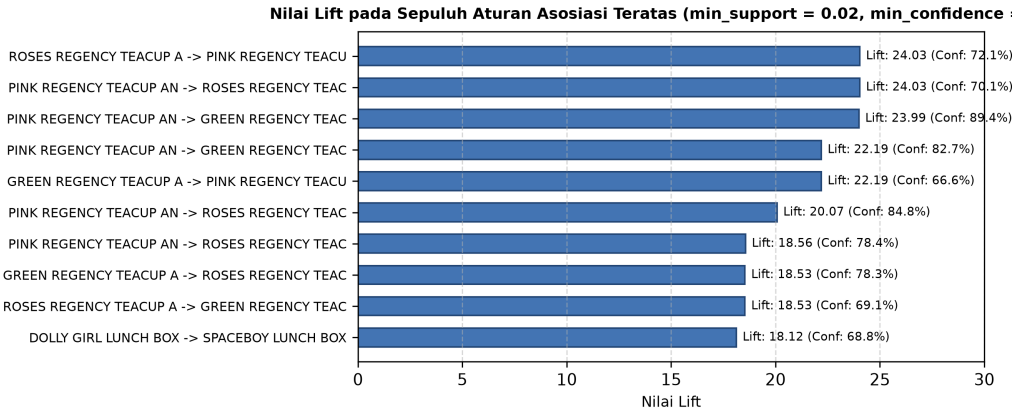
Konfigurasi min_support = 0,020 dan min_confidence = 0,60 dipilih sebagai model optimal, menghasilkan tepat 20 strong association rules. Seluruh 20 aturan memiliki nilai Lift > 1 (Retention Rate 100%), membuktikan bahwa pola yang terbentuk merupakan keterkaitan positif yang nyata.

Tabel 4: Sepuluh aturan asosiasi teratas berdasarkan nilai Lift (min_support = 0.02, min_confidence = 0.60)

Antecedents	Consequents	Support	Confidence	Lift	Leverage	Conviction
{GREEN REGENCY, ROSES REGENCY}	{PINK REGENCY TEACUP}	0,0210	0,7209	24,03	0,0202	3,48
{PINK REGENCY TEACUP}	{GREEN REGENCY, ROSES REGENCY}	0,0210	0,7014	24,03	0,0202	3,25
{PINK REGENCY, ROSES REGENCY}	{GREEN REGENCY TEACUP}	0,0210	0,8945	23,99	0,0202	9,12
{PINK REGENCY TEACUP}	{GREEN REGENCY TEACUP}	0,0248	0,8273	22,19	0,0237	5,58
{GREEN REGENCY TEACUP}	{PINK REGENCY TEACUP}	0,0248	0,6657	22,19	0,0237	2,90
{GREEN REGENCY, PINK REGENCY}	{ROSES REGENCY TEACUP}	0,0210	0,8478	20,07	0,0200	6,29
{PINK REGENCY TEACUP}	{ROSES REGENCY TEACUP}	0,0235	0,7842	18,56	0,0223	4,44
{GREEN REGENCY TEACUP}	{ROSES REGENCY TEACUP}	0,0292	0,7829	18,53	0,0276	4,41

Antecedents	Consequents	Support	Confidence	Lift	Leverage	Conviction
{ROSES REGENCY TEACUP}	{GREEN REGENCY TEACUP}	0,0292	0,6909	18,53	0,0276	3,11
{DOLLY GIRL LUNCH BOX}	{SPACEBOY LUNCH BOX}	0,0229	0,6883	18,12	0,0216	3,09

Gambar 3: Nilai Lift pada sepuluh aturan asosiasi teratas (min_support = 0.02, min_confidence = 0.60)



Analisis keterkaitan produk secara objektif berdasarkan 20 aturan terpilih:

1. Klaster Seri Regency Teacup and Saucer: Menempati peringkat teratas nilai Lift (24,03 hingga 18,53). Aturan {PINK, ROSES} -> {GREEN} mencatatkan nilai Confidence tertinggi yakni 89,45% dan Conviction 9,12. Pembeli cangkir teh warna Pink dan Roses memiliki kepastian 89,45% untuk turut membeli cangkir warna Green.
2. Klaster Kotak Makan Anak (Lunch Box): Pembelian DOLLY GIRL LUNCH BOX berasosiasi timbal balik dengan SPACEBOY LUNCH BOX dengan nilai Lift 18,12 dan Confidence 68,83% (sebaliknya: 60,23%).
3. Klaster Perlengkapan Berkebun (Gardeners Kneeling Pad): Kombinasi varian KEEP CALM dan CUP OF TEA memiliki Lift 17,88 dengan Confidence mencapai 72,91%.
4. Klaster Jam Beker Retro (Alarm Clock Bakelike): Hubungan komplementer warna Green, Red, dan Pink memiliki Lift antara 13,65 hingga 14,20 dan Confidence 60,43% hingga 67,17%.
5. Klaster Tas Belanja Jumbo & Dekorasi Rumah: JUMBO BAG PINK POLKADOT dan STRAWBERRY terasosiasi kuat menuju JUMBO BAG RED RETROSPOT (Lift ~7,3; Confidence > 62%), serta RED HANGING HEART T-LIGHT HOLDER menuju WHITE HANGING HEART T-LIGHT HOLDER (Lift 6,30; Confidence 67,01%).

Kesimpulan

Berdasarkan hasil eksperimen perbandingan algoritma Association Rule Mining (Apriori vs. FP-Growth) pada dataset Online Retail:

1. Kesetaraan Hasil dan Validitas Aturan:

Apriori dan FP-Growth menghasilkan himpunan frequent itemsets dan aturan asosiasi yang 100% konsisten pada setiap pengujian parameter. Seluruh 20 aturan yang terbentuk pada min_support = 0.02 dan min_confidence = 0.60 memiliki nilai Lift > 1 (antara 6,30 hingga 24,03), yang membuktikan adanya keterkaitan nyata (korelasi positif) antar-produk

2. Trade-off Waktu Komputasi & Skalabilitas:

FP-Growth terbukti jauh lebih terukur (scalable) pada threshold support rendah (min_support = 0,010), dengan waktu eksekusi 2,04 detik berbanding 29,57 detik pada Apriori (~14,5 kali lebih cepat). Sebaliknya, pada nilai support lebih tinggi (min_support >= 0,020), Apriori berjalan sedikit lebih cepat karena ketiadaan overhead konstruksi pohon FP-Tree.

Kesimpulan Akhir (Takeaway)

Nilai minimum support adalah parameter penentu utama dalam mengendalikan jumlah dan kualitas aturan asosiasi pada dataset transaksi ritel.

Untuk dataset transaksi berskala besar dengan variasi item tinggi (3.877 item unik), algoritma FP-Growth adalah pendekatan komputasi yang optimal untuk mengekstraksi pola transaksi pada ambang batas support rendah. Pola asosiasi yang terbentuk secara faktual menunjukkan ko-okurensi terkuat pada produk-produk yang merupakan varian desain dalam satu lini produk atau produk pelengkap dalam kategori utilitas yang sama.