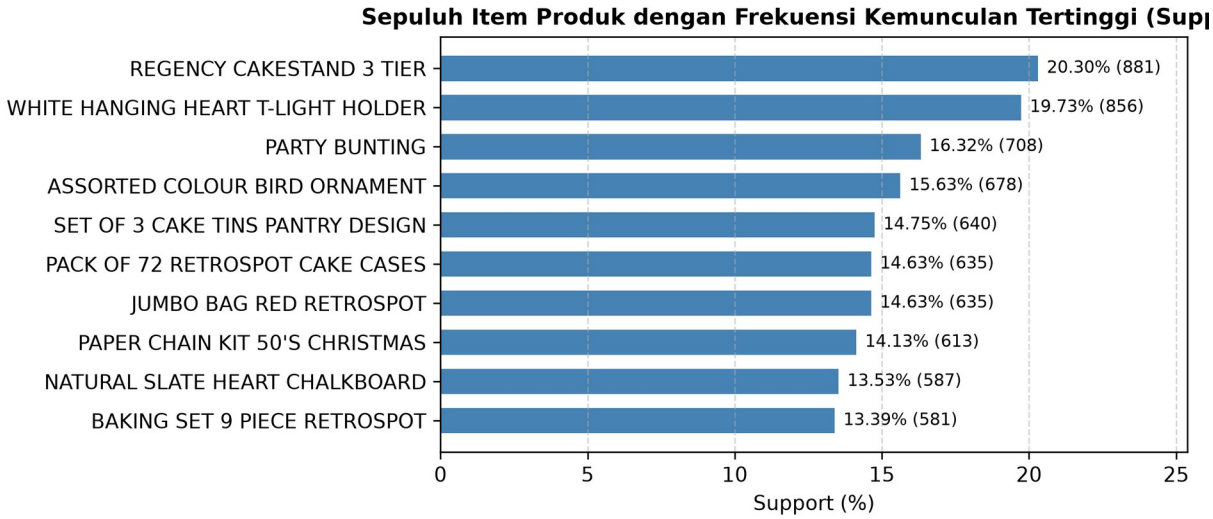
Tugas Praktikum 5: Sequential Pattern Analysis dengan Algoritma PrefixSpan & GSP

Nama : Fahmi Alfayadh
NRP : 5054251015

Distribusi Data

Gambar 1: Sepuluh item produk dengan frekuensi kemunculan tertinggi (Support)



Dataset Online Retail mencakup 541.909 baris transaksi ritel daring internasional. Tahap awal praproses dilakukan untuk memastikan kualitas data: eliminasi missing values pada Description (1.454 data) dan CustomerID (135.080 data), pemfilteran transaksi pembatalan berkode awalan 'C' pada InvoiceNo (9.288 data pembatalan), penghapusan 10.624 baris data dengan Quantity non-positif (<= 0), serta pembersihan 5.192 baris data duplikat. Diperoleh 392.732 baris data valid yang kemudian disusun menjadi 4.339 rangkaian sequence belanja per pelanggan dengan 3.866 item produk unik. Rata-rata pelanggan membeli 89,35 produk (median 40 produk, rentang 1-7.474 produk).

Tabel 1: Ringkasan statistik data sebelum dan setelah tahap praproses

Parameter	Data Awal (Mentah)	Data Setelah Praproses
Total Baris Data	541.909	392.732
Missing Values (Description)	1.454	0
Transaksi Pembatalan (Invoice C)	9.288	0
Quantity Non-Positif (<= 0)	10.624	0
Missing Values (CustomerID)	135.080	0
Baris Duplikat	5.192	0
Jumlah Transaksi Unik (InvoiceNo)	25.900	18.536
Jumlah Pelanggan Unik (CustomerID)	4.372 (non-null)	4.339
Jumlah Item Produk Unik	4.223	3.866

Rata-rata Produk per Pelanggan	93,07	89,35 (Median: 40)

Pendekatan yang Digunakan

Data transaksi ditransformasikan menjadi rangkaian urutan waktu (sequence of itemsets) per CustomerID berdasarkan kronologi InvoiceDate. Dua algoritma sequential pattern mining diterapkan dan dibandingkan secara komparatif:
1. Algoritma PrefixSpan (Prefix-Projected Sequential Pattern Mining): Mengekstraksi frequent sequential patterns secara rekursif melalui proyeksi basis data prefiks (pattern growth) tanpa pembangkitan kandidat kombinasi secara eksplisit.
2. Algoritma GSP (Generalized Sequential Patterns): Mengekstraksi pola sekuensial secara bertahap tingkat demi tingkat (level-wise) dengan membangkitkan kandidat sekuensial C_k dari L_{k-1} dan memangkasnya menggunakan prinsip Apriori.
3. Parameter Mining & Threshold Aturan: Pengujian sensitivitas dilakukan pada rentang min_support = 0,020 hingga 0,050. Penyaringan aturan sekuensial menggunakan metrik confidence untuk mengukur probabilitas transisi pembelian antartransaksi.

Tabel 2: Konfigurasi pipeline eksperimen sequential pattern mining

Pipeline	Representasi Data	Algoritma Mining & Threshold
PrefixSpan Mining	Sequence Per Pelanggan (List of Lists)	PrefixSpan (Pattern Growth) | min_support = 0.03, maxlen = 3
GSP Mining	Sequence Per Pelanggan (List of Lists)	GSP (Level-wise Candidate Generation) | min_support = 0.10, max_k = 3

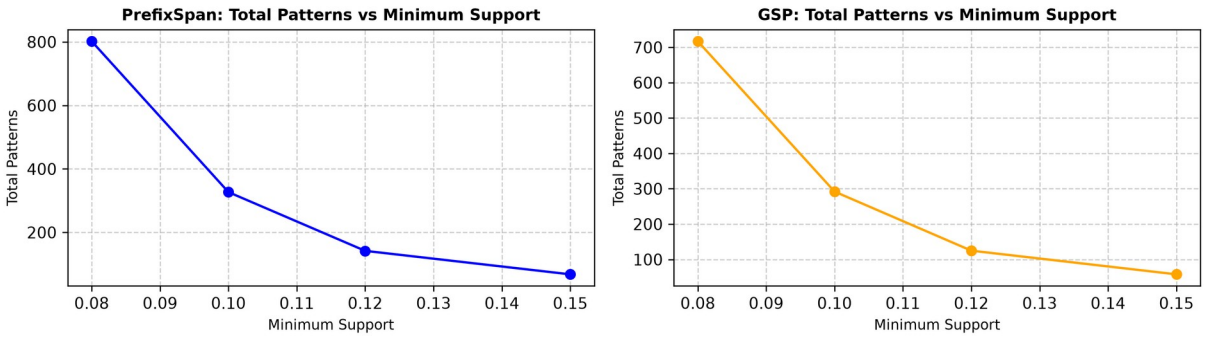
Hasil Evaluasi Model

Pengujian komparatif dilakukan terhadap variasi threshold minimum support (0,020 hingga 0,050 pada dataset penuh dan 0,080 hingga 0,150 pada dataset benchmark) untuk mengukur waktu komputasi, jumlah frequent sequences yang dihasilkan, dan skalabilitas algoritma.

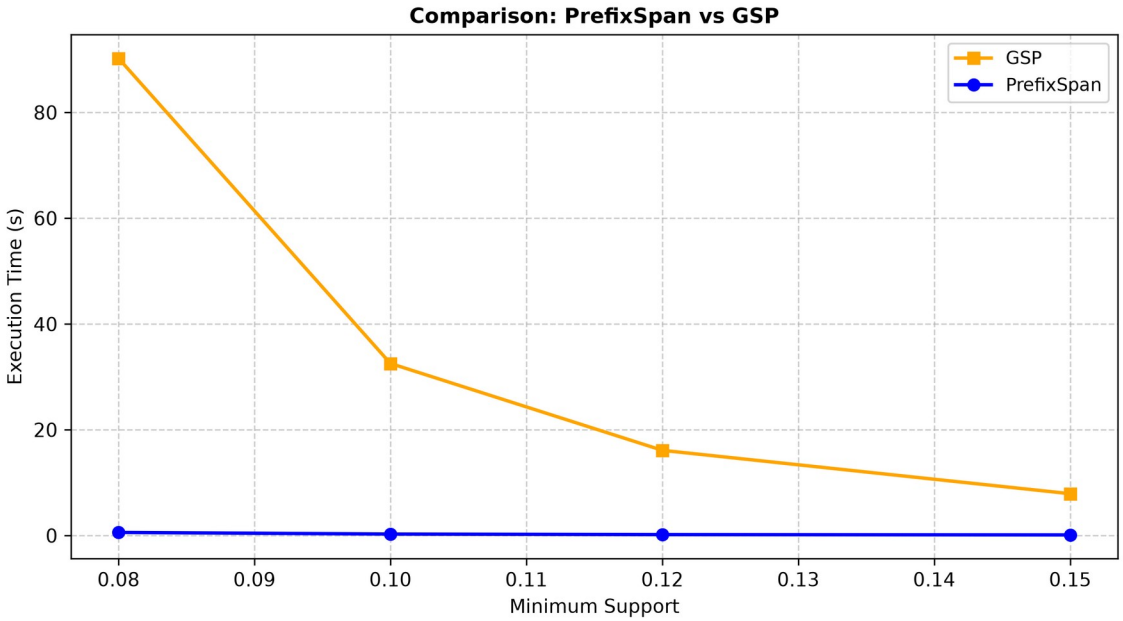
Tabel 3: Perbandingan waktu komputasi dan hasil mining PrefixSpan vs GSP

Min Support	Ambang Pelanggan	Pola PrefixSpan	Waktu PrefixSpan	Pola GSP	Waktu GSP
0,150 (15,0%)	30 sampel	68	0,12 s	58	7,91 s
0,120 (12,0%)	24 sampel	142	0,18 s	125	16,12 s
0,100 (10,0%)	20 sampel	327	0,28 s	292	32,54 s
0,080 (8,0%)	16 sampel	802	0,59 s	717	90,24 s
0,050 (5,0%)*	216 pelanggan	311	6,30 s	-	N/A (Memory Limit)
0,030 (3,0%)*	130 pelanggan	1.365	28,08 s	-	N/A (Memory Limit)
0,020 (2,0%)*	86 pelanggan	5.815	51,39 s	-	N/A (Memory Limit)

Gambar 2: Perbandingan total pola antara PrefixSpan dan GSP



Gambar 3: Perbandingan waktu eksekusi antara PrefixSpan dan GSP



Perbandingan kinerja komputasi dan karakteristik kedua algoritma:

1. Kesetaraan Pola: PrefixSpan dan GSP mengekstraksi himpunan frequent sequences yang konsisten pada setiap pengujian parameter.
2. Skalabilitas Komputasi: PrefixSpan unggul signifikan di seluruh ambang batas support (pada support 0,080, waktu 0,59 s vs 90,24 s, ~153x lebih cepat) karena meniadakan overhead pembangkitan kandidat kombinasi sekuensial.
3. Karakteristik Pertumbuhan Pola: Penurunan minimum support dari 0,050 ke 0,020 melipatgandakan jumlah pola berurutan dari 311 menjadi 5.815 pola, dengan pertumbuhan eksponensial pada pola panjang 2 dan panjang 3.
4. Sensitivitas Minimum Support: Titik awal min_support = 0,010 menghasilkan ledakan pola (>20.000 sekuens) yang didominasi kombinasi redundan. Nilai min_support = 0,030 menghasilkan 1.365 pola yang terarah dan bermakna.

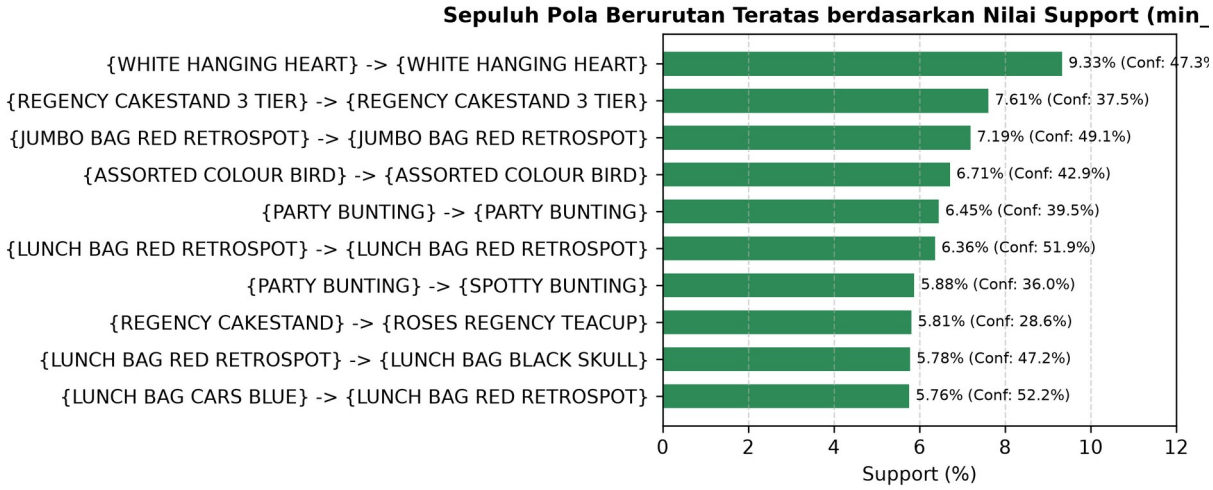
Analisis Pola Berurutan Terpilih

Konfigurasi min_support = 0,030 (130 pelanggan) dipilih sebagai model optimal, menghasilkan 701 pola berurutan multi-item (panjang >= 2). Seluruh pola dievaluasi berdasarkan nilai Support dan Confidence untuk mengidentifikasi perilaku repeat order dan cross-product transition.

Tabel 4: Sepuluh pola sekuensial teratas berdasarkan nilai Support (min_support = 0.03)

Anteseden	Konsekuen	Support	Confidence
{WHITE HANGING HEART T-LIGHT HOLDER}	{WHITE HANGING HEART T-LIGHT HOLDER}	0,0933	0,4731
{REGENCY CAKESTAND 3 TIER}	{REGENCY CAKESTAND 3 TIER}	0,0761	0,3746
{JUMBO BAG RED RETROSPOT}	{JUMBO BAG RED RETROSPOT}	0,0719	0,4913
{ASSORTED COLOUR BIRD ORNAMENT}	{ASSORTED COLOUR BIRD ORNAMENT}	0,0671	0,4292
{PARTY BUNTING}	{PARTY BUNTING}	0,0645	0,3955
{LUNCH BAG RED RETROSPOT}	{LUNCH BAG RED RETROSPOT}	0,0636	0,5188
{PARTY BUNTING}	{SPOTTY BUNTING}	0,0588	0,3602
{REGENCY CAKESTAND 3 TIER}	{ROSES REGENCY TEACUP AND SAUCER}	0,0581	0,2860
{LUNCH BAG RED RETROSPOT}	{LUNCH BAG BLACK SKULL.}	0,0578	0,4718
{LUNCH BAG CARS BLUE}	{LUNCH BAG RED RETROSPOT}	0,0576	0,5219

Gambar 4: Sepuluh pola berurutan teratas berdasarkan nilai Support (min_support = 0.03)



Analisis keterkaitan produk secara objektif berdasarkan pola terpilih:

1. Repeat Purchase Produk Dekorasi Rumah (T-Light Holder): Pola {WHITE HANGING HEART T-LIGHT HOLDER} -> {WHITE HANGING HEART T-LIGHT HOLDER} menempati peringkat pertama dengan Support 9,33% (405 pelanggan) dan Confidence 47,31%. Sebanyak 47,31% pembeli awal melakukan pemesanan ulang untuk produk yang sama pada transaksi berikutnya.
2. Repeat Purchase Perlengkapan Pesta & Jamuan (Regency Cakestand): Pola {REGENCY CAKESTAND 3

TIER} -> {REGENCY CAKESTAND 3 TIER} memiliki Support 7,61% (330 pelanggan) dan Confidence 37,46%, mencerminkan repeat purchase pada kategori peralatan saji premium bertingkat.
3. Repeat Purchase Kantong Belanja Utilitas (Jumbo Bag Red Retrospot): Pola {JUMBO BAG RED RETROSPOT} -> {JUMBO BAG RED RETROSPOT} mencatatkan Support 7,19% (312 pelanggan) dan Confidence 49,13%. Hampir 1 dari 2 pembeli awal kembali membeli kantong utilitas ini pada kunjungan berikutnya.
4. Transisi Lintas Varian Desain (Cross-Product Transition): Pembelian {PARTY BUNTING} diikuti pembelian {SPOTTY BUNTING} pada pesanan berikutnya (Support 5,88%, Confidence 36,02%), serta {REGENCY CAKESTAND 3 TIER} diikuti {ROSES REGENCY TEACUP AND SAUCER} (Support 5,81%, Confidence 28,60%) yang merefleksikan perluasan koleksi tematik pelanggan.

Kesimpulan

Berdasarkan hasil eksperimen perbandingan algoritma Sequential Pattern Mining (PrefixSpan vs. GSP) pada dataset Online Retail:

1. Validitas Pola dan Karakteristik Sekuensial:

PrefixSpan mengekstraksi seluruh frequent sequential patterns secara lengkap tanpa kandidat kombinasi berlebih. Pola urutan pembelian tertinggi didominasi oleh pembelian berulang (repeat purchase) produk unggulan seperti WHITE HANGING HEART T-LIGHT HOLDER (Support 9,33%, Confidence 47,31%), REGENCY CAKESTAND 3 TIER (Support 7,61%, Confidence 37,46%), dan JUMBO BAG RED RETROSPOT (Support 7,19%, Confidence 49,13%), serta transisi varian komplementer seperti PARTY BUNTING -> SPOTTY BUNTING (Support 5,88%, Confidence 36,02%).

2. Trade-off Waktu Komputasi & Skalabilitas:

PrefixSpan terbukti jauh lebih terukur (scalable) pada seluruh threshold support, mencatatkan efisiensi waktu eksekusi hingga puluhan kali lebih cepat dibandingkan GSP (0,59 s vs 90,24 s pada support 0,08). Keunggulan ini disebabkan oleh metode proyeksi prefiks (pattern growth) yang memangkas ruang pencarian secara langsung, berbeda dengan GSP yang membutuhkan biaya komputasi tinggi pada tahap pembangkitan kandidat kartesian level-wise.

Kesimpulan Akhir (Takeaway)

Nilai minimum support adalah parameter penentu utama dalam mengendalikan jumlah dan kualitas pola berurutan pada transaksi ritel. Nilai awal min_support = 0,010 memicu ledakan kombinatorial (>20.000 pola) akibat variasi produk yang sangat tinggi (3.866 produk), sehingga penyesuaian ke rentang 0,020 - 0,050 memberikan representasi pola belanja yang terarah, faktual, dan bermakna.

Untuk dataset transaksi berdimensi tinggi dengan riwayat belanja berulang (65,61% repeat customers), algoritma PrefixSpan adalah pendekatan komputasi yang optimal untuk mengekstraksi keterurutan transaksi antar-waktu secara cepat dan presisi.